



上海交通大学硕士学位论文

上海交通大学学位论文 L^AT_EX 模板示例文档

姓 名：黄 土

学 号：123033910031

导 师：阮 娜

院 系：计算机学院

学 科 / 专 业：计算机科学与技术专业

申 请 学 位：工学硕士

2026 年 4 月 9 日

**A Dissertation Submitted to
Shanghai Jiao Tong University for the Degree of Master**

**A SAMPLE DOCUMENT FOR L^AT_EX-BASED SJTU
THESIS TEMPLATE**

Author: Tu Huang
Supervisor: Prof. Na Ruan

School of Computer Science
Shanghai Jiao Tong University
Shanghai, P.R. China
April 9th, 2026

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全知晓本声明的法律后果由本人承担。

学位论文作者签名：

日期： 年 月 日

上海交通大学

学位论文使用授权书

本人同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于：

☐ 公开论文

☐ 内部论文，保密 ☐ 1 年 / ☐ 2 年 / ☐ 3 年，过保密期后适用本授权书。

☐ 秘密论文，保密 ____ 年（不超过 10 年），过保密期后适用本授权书。

☐ 机密论文，保密 ____ 年（不超过 20 年），过保密期后适用本授权书。

（请在以上方框内选择打“√”）

学位论文作者签名：

指导教师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

中文摘要应该将学位论文的内容要点简短明了地表达出来，应该包含论文中的基本信息，体现科研工作的核心思想。摘要内容应涉及本项科研工作的目的和意义、研究方法、研究成果、结论及意义。注意突出学位论文中具有创新性的成果和新见解的部分。摘要中不宜使用公式、化学结构式、图表和非公知公用的符号和术语，不标注引用文献编号。硕士学位论文中文摘要字数为 500 字左右，博士学位论文中文摘要字数为 800 字左右。英文摘要内容应与中文摘要内容一致。

摘要页的下方注明本文的关键词（4~6 个）。

关键词：上海交大，饮水思源，爱国荣校

Abstract

Shanghai Jiao Tong University (SJTU) is a key university in China. SJTU was founded in 1896. It is one of the oldest universities in China. The University has nurtured large numbers of outstanding figures include JIANG Zemin, DING Guangen, QIAN Xuesen, Wu Wenjun, WANG An, etc.

SJTU has beautiful campuses, Bao Zhaolong Library, Various laboratories. It has been actively involved in international academic exchange programs. It is the center of CERNet in east China region, through computer networks, SJTU has faster and closer connection with the world.

Key words: SJTU, master thesis, XeTeX/LaTeX template

目 录

第 1 章 绪论	1
1.1 研究背景与意义.....	1
1.1.1 联邦学习的兴起与安全威胁	1
1.1.2 个性化联邦学习的发展与安全挑战	2
1.1.3 现有防御方法的局限性分析	3
1.2 国内外研究现状.....	4
1.2.1 个性化联邦学习研究进展	4
1.2.2 联邦学习中的后门攻击研究	5
1.2.3 联邦学习中的后门防御研究	6
1.3 本文研究内容与主要贡献.....	7
1.3.1 研究内容概述	7
1.3.2 主要贡献	8
1.4 论文结构安排.....	9
第 2 章 相关理论基础	10
2.1 联邦学习与个性化联邦学习.....	10
2.1.1 联邦学习基本框架	10
2.1.2 数据异构性与个性化建模	11
2.1.3 个性化联邦学习的主要方法	12
2.2 后门攻击基础.....	13
2.2.1 后门攻击的形式化定义	13
2.2.2 集中式学习中的典型后门攻击	14
2.2.3 联邦学习中的后门攻击	15
2.2.4 个性化联邦学习中后门攻击的特殊性	16
2.3 联邦学习后门防御方法.....	17
2.3.1 基于鲁棒聚合的服务器端防御	17
2.3.2 基于异常检测与过滤的防御	18
2.3.3 基于模型净化的防御	18

2.3.4 现有防御方法在 PFL 场景中的局限性.....	19
2.4 对抗训练与后门净化的关联.....	19
2.5 本章小结.....	20
第 3 章 FedCLCM: 面向个性化联邦学习的协同后门防御方法	22
3.1 引言.....	22
3.2 问题定义.....	22
3.2.1 系统模型	22
3.2.2 威胁模型	23
3.2.3 防御目标	24
3.3 FedCLCM 总体框架.....	24
3.3.1 设计思路	24
3.3.2 方法组成	26
3.3.3 整体流程	26
3.4 客户端侧鲁棒个性化训练.....	26
3.4.1 两阶段交替训练	26
3.4.2 触发器破坏型增强	27
3.4.3 双视图特征一致性约束	28
3.4.4 客户端本地目标函数	29
3.4.5 客户端侧训练算法	29
3.5 服务器端通道感知修剪聚合.....	30
3.5.1 通道方差建模	30
3.5.2 软掩码生成	31
3.5.3 掩码引导修剪均值聚合	32
3.5.4 服务器端聚合算法	32
3.6 理论分析.....	32
3.6.1 客户端一致性约束的作用分析	32
3.6.2 服务器端掩码聚合的抑制效果	33
3.6.3 计算复杂度分析	34
3.7 本章小结.....	34
第 4 章 实验设置与结果分析	36
4.1 引言.....	36

4.2 实验设置.....	36
4.2.1 数据集与模型设置	36
4.2.2 数据划分与训练细节	37
4.2.3 攻击设置	37
4.2.4 对比方法与评价指标	37
4.3 整体防御效果分析.....	38
4.3.1 与现有方法的总体比较	38
4.4 影响因素分析.....	39
4.4.1 恶意客户端数量的影响	39
4.4.2 数据个性化程度的影响	40
4.4.3 触发器模式变化的影响	40
4.4.4 裁剪比例 β 的影响	41
4.5 本章小结.....	41
参考文献.....	43
致 谢.....	45
学术论文和科研成果目录.....	46
个人简历.....	47

插图

- 图 2.1 标准联邦学习的一轮通信流程示意图。蓝色实线表示服务器向各客户端下发全局模型参数 $\mathbf{w}^t$ ，橙色虚线表示各客户端在本地数据上完成若干步梯度更新后将参数 $\mathbf{w}_k^{t+1}$ 上传至服务器。服务器按样本量加权执行 FedAvg 聚合，得到新一轮全局模型 $\mathbf{w}^{t+1}$ 。原始数据 $\mathcal{D}_k$ 始终保留在客户端本地，不参与任何形式的通信。..... 11
- 图 2.2 个性化联邦学习中的 Base-Head 参数解耦结构示意图。左侧绿色区域为共享特征提取器 (base)，包含若干卷积层和全连接层，其参数 θ_B 由服务器统一聚合与下发，所有客户端共享同一版本；右侧紫色区域为私有分类头 (head)，每个客户端 k 保有各自的 θ_{H_k} ，根据本地数据独立训练，不参与联邦通信。原始输入 $\mathbf{x}$ 经 base 映射为 d 维特征表示 $\mathbf{z}$ ，再由各客户端的私有 head 完成最终分类预测。..... 13
- 图 3.1 FedCLCM 完整系统架构图。左侧绿色区域为诚实客户端 (以 i_1 、 i_2 为例)，每个客户端的本地训练流程依次为：触发器破坏型增强 $\mathcal{A}_{tb}$ 、双视图生成 ($\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$)、共享 base 特征提取、特征一致性损失 $\mathcal{L}_{cl}$ 计算，最终以 $\mathcal{L}_{base} = \mathcal{L}_{ce} + \lambda_{cl}\mathcal{L}_{cl}$ 为目标更新共享 base 参数；右侧蓝色区域为中央服务器，依序执行四步：计算各层通道更新量 $\Delta_i^{t,l}$ 、通道方差评分 $v_c^{t,l}$ 、生成软掩码 $\mathbf{M}^{t,l}$ 、修剪均值聚合输出全局参数 θ_B^{t+1} ；下方红色区域为恶意客户端，上传含后门的参数。蓝色实线表示下发，绿色虚线表示诚实上传，红色虚线表示恶意上传。..... 25

表 格

表 2.1 主流个性化联邦学习方法特点比较..... 14

表 2.2 集中式学习中典型后门触发器设计方式比较..... 15

表 2.3 联邦后门防御方法在 PFL 场景中的局限性比较 19

表 4.1 不同方法在各数据集上的整体性能比较..... 38

表 4.2 不同恶意客户端数量下各方法在 CIFAR-10(R) 上的性能比较..... 39

表 4.3 不同数据个性化程度下各方法在 CIFAR-10(R) 上的性能比较..... 40

表 4.4 不同触发器模式下 AdvPurge 的性能比较 41

表 4.5 不同裁剪比例 β 下 AdvPurge 在 CIFAR-10(R) 上的性能比较 41

算 法

算法 3.1 FedCLCM 整体训练流程（概要） 27

算法 3.2 FedCLCM 诚实客户端本地训练 30

算法 3.3 FedCLCM 服务器端聚合 33

符号对照表

ϵ 介电常数

μ 磁导率

ϵ 介电常数

μ 磁导率

ϵ 介电常数

μ 磁导率

第1章 绪论

1.1 研究背景与意义

1.1.1 联邦学习的兴起与安全威胁

近年来,以深度神经网络为代表的人工智能技术在医疗影像辅助诊断、金融信用风控、智能移动终端以及工业质量检测等众多领域取得了突破性进展,模型对数据规模与数据多样性的依赖程度也随之不断加深。然而,现实中的数据往往分散在不同机构、不同设备乃至不同国家的主体之中,既受制于个人隐私保护法规(如欧盟通用数据保护条例 GDPR),又受到商业竞争与数据主权等因素的制约,难以直接汇聚用于集中式训练。这种数据“可用而不可见”的矛盾,在相当程度上限制了人工智能技术在高敏感场景中的落地。

为了在不共享原始数据的前提下实现多方协同建模,联邦学习(Federated Learning, FL)于2017年由 McMahan 等人正式提出^[1]。联邦学习的核心思想是,各参与方(客户端)只在本地进行模型训练,而后将模型参数或梯度上传至中央服务器,由服务器执行聚合并将更新后的全局模型下发给各客户端,如此循环往复直至模型收敛。由于原始数据始终保留在本地,这一范式被视为兼顾模型性能与数据隐私的重要技术路线,并在移动键盘输入预测、医疗图像分析协同以及跨机构信用评估等场景中取得了实际应用。

然而,联邦学习的分布式协同机制本身也埋下了新的安全隐患。在集中式训练中,数据的来源与质量处于服务器的直接管控之下;而在联邦学习中,服务器只能获得各客户端上传的模型参数,既无法访问客户端的本地数据,也无法对本地训练过程进行验证。这一“不可见性”为恶意参与者的攻击行为提供了隐蔽空间。在众多针对联邦学习的攻击手段中,后门攻击(Backdoor Attack)因其高度隐蔽性与持续性而尤为值得关注。后门攻击的目标不是破坏模型的整体性能,而是在模型中植入一条隐蔽的“触发器-目标标签”映射路径:模型在处理普通干净样本时行为正常,但一旦输入包含特定触发器(如特定图案、特定颜色块或特定信号叠加)的样本,模型便会输出攻击者预先设定的错误标签。由于这种攻击在日常使用中不会引发性能异常,常规的精度监测手段几乎无法察觉。

已有研究表明,联邦学习中的后门攻击可通过多种途径实现。攻击者可以控制一

定比例的恶意客户端，在本地训练数据中掺入携带触发器的中毒样本，使本地模型学习到后门映射关系，再将含有后门的模型参数上传至服务器参与聚合；也可以直接对本地模型参数进行操控，通过特殊的参数缩放或投影操作来放大后门特征在聚合后模型中的保留程度。前者称为数据投毒驱动的攻击，后者称为模型投毒驱动的攻击^[2]，两者在实践中往往被联合使用，以追求更高的攻击成功率。

1.1.2 个性化联邦学习的发展与安全挑战

尽管联邦学习在缓解数据孤岛问题上取得了积极进展，但在现实部署场景中，客户端数据往往并不满足独立同分布（IID）假设。以跨机构医学影像联合诊断为例，不同医院在病患人群构成、影像采集设备、标注规范和检查侧重等方面均存在显著差异，导致各机构持有的数据在类别分布、特征空间乃至标签体系上都可能截然不同。这种数据的非独立同分布性（Non-IID）会导致各客户端的本地优化目标相互冲突，在 FedAvg^[1]等标准聚合算法的框架下，全局模型往往只能代表各客户端数据分布的某种“折中”，而非真正满足每个客户端的本地需求。实验研究表明，当数据异质性较强时，标准联邦学习的模型精度相比本地独立训练可能出现显著下降，这一问题被称为“客户端漂移”（Client Drift）。

为了在联邦协作框架下为每个客户端生成更符合其本地数据分布的模型，个性化联邦学习（Personalized Federated Learning, PFL）逐渐成为近年来的研究热点^[3]。与标准联邦学习的目标（训练单一全局模型）不同，PFL 更关注如何在全局知识共享的基础上为不同客户端生成具有差异化适配能力的个性化模型。目前，PFL 方法大致可分为基于完整模型共享的方法和基于参数解耦的方法两大类。前者（如 Per-FedAvg^[4]、Ditto^[5]等）通过元学习初始化或本地正则化约束实现个性化；后者（如 FedRep^[6]、FedBN^[7]等）则将模型参数显式划分为在客户端间共享的特征提取层（base）与保留在本地的分类头（head），仅对共享层执行联邦聚合，从而在通信效率与个性化能力之间取得较好的平衡。参数解耦类方法凭借其结构上的清晰性和较好的实际性能，已成为当前 PFL 研究中被广泛采用的技术路线之一。

然而，PFL 场景中的后门安全问题要比传统联邦学习中更为复杂。一方面，部分研究者最初期望 PFL 中的本地个性化训练过程能够通过利用干净本地数据对模型进行再训练，自然地“稀释”共享模型中遗留的后门痕迹，从而将个性化机制视为一种天然的后门防御手段。另一方面，这一乐观预期在后续研究中被多次证伪。Qin 等人^[8]在 KDD 2023 的工作中指出，个性化过程对简单后门的削弱效果高度依赖模型结构和

触发器设计，在深层网络上攻击成功率仍然可观^[8]；USENIX Security 2024 上的研究进一步表明，攻击者可以通过约束后门任务与主任务的梯度方向，使后门在本地个性化训练后依然得以保留，同时规避服务器端和客户端侧的现有防御^[9]。ICLR 2025 上提出的 Bad-PFL 方法^[10]则更进一步揭示，以自然数据中的语义特征作为触发载体，可以从根本上规避个性化过程对传统手工触发器的“遗忘效应”。上述研究共同表明，PFL 并非后门攻击的天然屏障，针对 PFL 场景设计有效的后门防御机制仍是一个亟待深入研究的开放问题。

以智慧医疗场景为例，可以具体感受到这一安全威胁的严峻性。假设某联合影像诊断系统由多家医院共同参与，系统采用参数解耦的 PFL 框架，各医院共享特征提取层而保留各自的分类头。若其中某家医院成为恶意参与者，攻击者完全控制其本地训练数据和训练过程，便可以在本地数据中悄悄掺入带有特定水印图案的肺部 CT 样本，并将对应标签从“疑似病变”改为“正常”，通过多轮联邦训练将这一后门规律嵌入共享特征提取层。由于共享层参数会在聚合后被下发至所有参与医院并进入各院的个性化模型，所有医院的最终诊断模型都可能在遇到带有该水印的 CT 影像时将病变样本误判为正常，而在日常使用的干净样本上与未受攻击的模型精度几乎无差别。这一攻击的危害性不仅在于其可能直接影响诊断结论，还在于它在联邦学习框架内几乎不留下可供检测的异常痕迹。

1.1.3 现有防御方法的局限性分析

面对联邦学习中的后门攻击威胁，研究者已提出多类防御方法，但这些方法在 PFL 场景中均表现出较为明显的局限性。

以鲁棒聚合方法为代表的服务器端防御方案（如 Krum^[11]、Trimmed Mean^[12]、Bulyan 等）的核心假设是，在参与聚合的客户端中，良性客户端的更新在统计上具有较强的集中性，而恶意客户端的更新则因包含后门信息而显著偏离这一中心分布，可以通过距离度量或参数截断加以识别和过滤。这一假设在 IID 或弱异构的经典联邦学习场景中具有一定合理性。然而，在 PFL 场景中，客户端数据的高度异质性本身就会导致各客户端的模型更新呈现出较大的自然差异，良性更新与恶意更新在统计分布上的边界因此变得模糊，直接使用相似性阈值或参数截断可能误伤正常更新，进而损害个性化性能。

基于异常检测与过滤的防御方法（如 FoolsGold^[13]）在识别具有相似更新模式的协同攻击时有一定效果，但也面临类似的困境：在 Non-IID 场景中，由于良性客户

端本就可能因数据相似而产生相近的更新，该方法在区分“正常相似”与“恶意协同”时容易出现误判。此外，随着攻击者技术的进步，现代后门攻击（如 DBA^[14]、Bad-PFL^[10]等）已能够有效地将恶意更新的统计特征伪装成正常更新，进一步削弱了基于统计分析的检测手段的有效性。

客户端侧净化方法（如通过剪枝、模型精细调优或对比学习进行后门去除）在原理上更接近后门防御的根本，但在 PFL 场景中的可行性受到多方面约束。一方面，客户端设备的计算资源和存储容量通常有限，无法支持复杂的后门逆向分析或大规模模型重训；另一方面，客户端的本地数据规模往往较小，若完全依赖本地数据执行强度较大的净化操作，很可能损害模型的个性化性能而非提升安全性。更根本的问题在于，当后门已经嵌入共享层参数并在每轮聚合后持续“刷新”时，单纯的客户端侧净化无法从根本上阻断后门在联邦网络中的持续传播。

从上述分析中不难看出，现有防御方法在应对 PFL 场景下的后门攻击时，共同面临三个层面的困难：一是方法假设与 PFL 数据异构性之间的结构性错配，导致检测精度下降；二是单侧防御（只在服务器端或只在客户端侧）无法覆盖后门从本地训练到全局聚合的完整传播链路；三是以整层或整客户端为粒度的粗放处理方式，与后门在模型内部集中于少数特定通道的精细结构之间存在不匹配。这三方面问题共同指向了本文工作的核心出发点：面向 PFL 场景，设计一种在客户端侧和服务端双向协同、防御粒度更细、对数据异构性更鲁棒的后门防御机制。

1.2 国内外研究现状

1.2.1 个性化联邦学习研究进展

个性化联邦学习的研究可以从优化目标与模型结构两个维度来理解。在优化目标层面，标准联邦学习的目标是寻找对所有客户端的平均性能最优的全局模型参数，而 PFL 则将优化目标转向每个客户端自身在本地分布上的性能，从而在联邦框架内引入了差异化的个性化考量。在模型结构层面，不同的 PFL 方法对“哪些知识可以共享”以及“个性化信息如何保留”给出了不同的回答，由此形成了各具特色的技术路线。

在基于完整模型共享的 PFL 方法中，Per-FedAvg^[4]引入了基于模型无关元学习（MAML）的思想，将全局模型训练为一个“元初始化”，使各客户端能够通过少量梯度更新步骤快速适配本地数据分布。这一方法在任务差异较大的场景中具有明显优势，但其代价是训练过程中需要进行二阶梯度计算，通信与计算开销较大。Ditto^[5]提

出了一种更轻量的正则化方案,通过在每个客户端维护独立的个性化模型参数,并以全局模型为正则化锚点来约束个性化模型的偏离程度,在全局知识共享与本地自适应之间寻求折中。这类方法的特点是实现较为简洁,适用于结构多样的网络,但当客户端间数据差异过大时,全局模型本身的质量会成为个性化效果的瓶颈。

在基于参数解耦的 PFL 方法中, FedRep^[6]率先提出将模型划分为共享特征表示层 (base) 和私有分类头 (head) 的结构,并在交替训练框架下分别优化两部分参数。服务器聚合仅作用于 base 参数,分类头完全保留在本地并根据本地数据独立更新。这一设计使得 base 专注于提取跨客户端可迁移的通用特征,而 head 则根据本地标签空间进行精细适配,从而在通信效率与个性化性能之间实现较好的平衡。FedBN^[7]的思路有所不同,它将批归一化 (Batch Normalization) 层视为刻画本地特征分布的关键组件,在聚合时将其作为私有层保留在客户端,只聚合其余参数,从而使模型更好地适应不同客户端的特征空间偏移。LG-FedAvg 等方法则探索了在边缘设备上仅共享全局特征表示、本地维护完整分类网络的可能性。此外, FedProto^[15]从表示层面而非参数层面出发,提出通过在客户端间共享类别原型 (prototype) 来对齐跨客户端的特征空间,以减少 Non-IID 数据带来的分布偏移影响,为个性化联邦学习提供了一种不依赖参数聚合的新思路。

综合来看,参数解耦类方法因其结构清晰、实现高效而逐渐成为 PFL 研究的主流方向,但现有工作在安全性分析层面的积累仍然相对薄弱,尤其是对于 base-head 分离结构下后门攻击的传播机制及其有效防御方案,目前尚缺乏系统性的深入研究。

1.2.2 联邦学习中的后门攻击研究

后门攻击最初在集中式深度学习场景中被提出和系统研究。Gu 等人提出的 BadNets^[16]通过在训练样本中叠加固定图案并修改对应标签,使模型在训练完成后对含有该图案的输入输出指定目标类别,从而确立了图像分类后门攻击的基础范式。由于 BadNets 的触发图案固定且局部化,其视觉上容易被识别,后续工作开始着力提升触发器的隐蔽性。Chen 等人提出的 Blended 攻击^[17]通过将参考图案以低透明度融合进原始图像,使触发器难以被肉眼察觉; Barni 等人提出的 SIG 攻击^[18]则将正弦信号作为触发器叠加于图像全局,在频域空间实现隐蔽植入; Nguyen 等人提出的 WaNet^[19]更进一步,通过对图像施加弹性形变来实现触发器注入,完全绕过了对像素值的直接修改,使触发器几乎无法通过像素级分析检测。这些工作共同揭示了深度神经网络对“捷径特征” (shortcut features) 的高度敏感性:模型可以在保持对干净样本正常预测的

同时，额外学习一条由特定触发模式激活的异常决策路径。

联邦学习的分布式特性为后门攻击提供了更为有利的实施条件。Bagdasaryan 等人首次将后门攻击引入联邦学习场景，提出了模型替换（Model Replacement）攻击^[2]：攻击者在上传参数前对恶意更新进行线性放大，使少数恶意客户端的参数在加权聚合后对全局模型产生超比例影响。为降低单个恶意客户端的异常程度、规避服务器端的统计检测，Xie 等人进一步提出了分布式后门攻击（DBA）^[14]，将完整触发器分解为多个本地子触发器分配给协同的恶意客户端分别注入，使每个客户端上传的更新看起来更为正常。随着鲁棒聚合等防御手段的出现，攻击方向逐渐转向对恶意更新的伪装：攻击者尝试约束恶意更新的方向与幅度，使其在统计分布上更接近良性更新，从而规避基于距离度量或方差分析的检测手段。

PFL 场景给后门攻击带来了新的挑战与机遇。一方面，本地个性化训练会对共享模型进行再训练，可能削弱后门效果；另一方面，攻击者也可以利用 PFL 的训练机制来设计更难以消除的后门。Qin 等人^[8]系统研究了现有 PFL 算法对主流后门攻击的抵抗能力，发现浅层 CNN 在个性化后具有一定的天然防御效果，但在采用 ResNet 等深层网络时，后门攻击的成功率仍然较高，个性化过程并不能作为后门防御的可靠手段。Lyu 等人^[9]在此基础上设计了专门针对 PFL 的后门攻击，通过同时优化主任务损失和后门任务损失，并约束两者梯度方向相近，使后门在个性化训练后得以持续保留，甚至可以绕过多种现有防御机制。Fan 等人提出的 Bad-PFL^[10]则从触发器设计入手，指出传统手工触发器之所以在 PFL 个性化后容易被遗忘，根本原因在于触发器与正常特征之间存在明显的分布差异，本地重训练会将这种“异质性”作为噪声逐步消除。为此，Bad-PFL 利用自编码器从正常数据中提取语义特征作为触发载体，使后门与主任务特征深度融合，从而在个性化训练后依然能够稳定存活。这一研究表明，PFL 后门攻击正在从依赖外部触发信号向利用模型内部特征表示的方向演化，防御研究需要相应地从关注异常信号检测转向关注共享表示层的特征解耦。

1.2.3 联邦学习中的后门防御研究

针对联邦后门攻击的防御研究可以按照防御位置分为服务器端方法、客户端侧方法和聚合后净化方法三类。

服务器端防御方法通常在聚合阶段对客户端更新进行筛选或修正，以降低恶意更新的影响。Blanchard 等人提出的 Krum^[11]算法通过计算各客户端更新之间的欧式距离，选取与其他更新最为接近的若干更新参与聚合，以此剔除距离其他客户端较远

的潜在恶意更新。Yin 等人提出了基于坐标截断统计的鲁棒聚合方法，其中 Trimmed Mean 在每个参数维度上剔除最大和最小的若干极端值后取均值，Median 则直接以各客户端更新的中位数作为聚合结果^[12]；Guerraoui 等人提出的 Bulyan 在 Krum 的基础上进一步通过迭代选取候选客户端并对其进行截断聚合，以提高对拜占庭攻击的鲁棒性。这类方法的共同前提是良性更新在统计上具有较高一致性，因而在 IID 场景或攻击者数量较少时具有一定效果；但在 Non-IID 场景下，数据异构性引发的良性更新多样性会严重干扰上述判断标准，导致防御效果大幅下降。

FoolsGold^[13]针对多个恶意客户端提交高度相似的中毒更新（即协同攻击）的场景设计了一种自适应权重调节机制，通过追踪历史更新中的相似度来降低可疑客户端在聚合中的权重。这种方法在具体攻击场景下有一定效果，但在 PFL 中，不同客户端的数据相似度本身就可能较高（例如同一类型任务的多个参与方），容易造成误判。

客户端侧防御方法试图在本地训练或本地推理阶段检测并缓解后门效应。Liu 等人提出的 Fine-Pruning 方法通过对模型进行剪枝并随后用干净数据微调，来消除与后门触发器相关的神经元激活；基于激活统计的方法（如 Activation Clustering）则通过分析模型中间层的激活分布来识别中毒样本。Zhang 等人提出的 FLPurifier^[20]将对比学习的思想引入联邦后门防御，通过将全局模型中与触发器相关的特征提取路径与正常特征路径进行解耦，在聚合后对模型进行净化。这类方法在具有辅助干净数据的条件下往往取得较好的效果，但在实际联邦学习场景中，服务器或客户端通常不持有辅助数据，增加了方法的落地难度。

综合来看，现有联邦后门防御方法在 PFL 场景中的适用性均存在不同程度的局限：服务器端方法与 Non-IID 数据环境的不兼容性，客户端侧方法的资源约束和数据依赖，以及全局模型净化方法的辅助数据需求。更重要的是，上述方法大多针对传统联邦学习设计，对于 PFL 特有的训练机制（尤其是 base-head 分离结构下共享层与私有层的交互关系）缺乏针对性考量。如何在不依赖辅助数据、不暴露私有信息的前提下，为 PFL 提供有效且实用的后门防御机制，是本文研究的核心问题所在。

1.3 本文研究内容与主要贡献

1.3.1 研究内容概述

针对上述分析所揭示的问题，本文围绕个性化联邦学习中的后门防御展开研究，提出了 FedCLCM 防御框架。该框架以 base-head 分离的 PFL 训练结构为基础，从客户端侧鲁棒表示学习与服务器端结构化聚合两个层面协同应对后门威胁，在不依赖

任何辅助数据和触发器先验知识的前提下覆盖后门传播的完整链路。

本文的研究内容主要包括以下三个部分。

第一，后门攻击在个性化联邦学习中的传播机制分析。本文对 **base-head** 分离结构下后门攻击的传播路径进行了系统梳理，重点分析了恶意客户端如何通过污染共享 **base** 参数，使后门在良性客户端本地个性化训练后依然得以保留。这一分析明确了后门传播的关键节点，即共享特征提取器在训练过程中对异常触发模式的”记忆”以及在聚合过程中对异常通道的”扩散”，为防御设计提供了明确的切入点。

第二，客户端侧触发器破坏型增强与特征一致性约束机制。在诚实客户端的本地训练阶段，**FedCLCM** 通过触发器破坏型增强算子对输入样本中的局部区域进行随机擦除与噪声填充，系统性地打断模型对局部固定触发模式的稳定记忆。在共享 **base** 的训练阶段，进一步通过双视图特征一致性约束引导 **base** 学习对轻微局部扰动具有稳健性的语义表示，从而在不依赖任何触发器先验知识的前提下主动降低后门特征在共享表示中的可学习性。

第三，服务器端通道方差感知软掩码与修剪均值协同聚合机制。在每轮聚合前，**FedCLCM** 通过统计各卷积层输出通道在不同客户端更新之间的方差，以通道级统计离散度为评分依据识别可能承载后门特征的可疑通道，并对每个客户端上传的共享参数施加基于软掩码的通道级降权，随后执行基于参数排序的修剪均值聚合。这种”软掩码降权与修剪均值结合”的双重抑制机制，在 **Non-IID** 异构场景中实现了比整层截断更精准的防御效果。

1.3.2 主要贡献

本文的主要贡献体现在以下三个方面。

第一，提出了一种面向个性化联邦学习的双侧协同后门防御框架 **FedCLCM**，将客户端侧主动表示净化与服务器端结构化聚合有机融合，在不依赖辅助数据和触发器先验的前提下，构建了覆盖后门传播完整链路的防御机制。与现有以服务器端或客户端单侧为主的防御方法相比，**FedCLCM** 能够在本地训练阶段减少后门特征的”写入”、在聚合阶段降低异常通道的”扩散”，两端防御相互补充，有效提升了系统对持续性后门攻击的整体抵抗能力。

第二，设计了基于通道方差统计的软掩码生成机制与修剪均值协同聚合策略。区别于现有鲁棒聚合方法以整客户端为异常判断粒度的做法，本文以卷积层输出通道为单位构建跨客户端更新的方差评分，能够在 **Non-IID** 数据环境下以更细的粒度识别

后门在模型内部的集中位置，并通过软降权（而非硬裁剪）的方式保留可疑通道的部分有效信息，与修剪均值聚合配合使用，在降低后门影响的同时有效控制对正常个性化更新的误伤程度。

第三，提出了触发器破坏型增强与双视图特征一致性约束相结合的客户端侧净化机制。该机制无需逆向推断触发器的具体形态，仅通过局部区域的随机擦除与噪声填充来破坏触发模式的结构可复现性，再结合轻量级的双视图一致性约束将共享 base 引导向语义稳定的表示方向。两种机制相互配合，以较低的额外计算代价实现了共享特征提取器鲁棒性的主动强化，有效补充了服务器端聚合防御的不足。

1.4 论文结构安排

本论文共分为五章，各章节内容安排如下。

第一章为绪论，对研究背景与意义、国内外研究现状以及本文的研究内容与主要贡献进行了系统性阐述，并说明了各章节的组织安排。

第二章为相关理论基础，系统介绍了联邦学习的基本框架与个性化联邦学习的主要方法，对后门攻击的工作原理与联邦场景中的主要攻击形式进行了形式化描述与分类梳理，并归纳了现有联邦后门防御方法的主要思路及其在 PFL 场景中的局限性，最后讨论了对抗训练与后门防御之间的关联，为第三章方法设计提供理论依据。

第三章为 FedCLCM 方法设计，详细介绍了本文所提出的防御框架的系统模型、威胁模型与防御目标，从客户端侧鲁棒个性化训练与服务器端通道感知修剪聚合两个层面完整阐述了 FedCLCM 的设计思路与实现细节，并给出了算法伪代码与相关理论分析。

第四章为实验验证，在 MNIST、FashionMNIST 与 CIFAR-10 三个基准数据集上，通过与多种基线方法的对比实验系统验证了 FedCLCM 在不同攻击类型、不同数据异构程度和不同恶意客户端比例下的防御有效性，并通过消融实验分析了各核心模块的独立贡献。

第五章为总结与展望，对全文工作进行概括，归纳了本文研究的主要结论，并对未来可能的研究方向进行了展望。

第2章 相关理论基础

本章对论文研究所需的理论背景与相关工作进行系统梳理，重点围绕联邦学习框架、个性化联邦学习方法、后门攻击原理与分类、联邦后门防御方法，以及对抗训练与后门净化的内在关联五个方面展开。通过对上述内容的系统回顾，本章旨在明确 PFL 后门防御领域的现有研究积累与尚待解决的问题，并为后续 FedCLCM 方法的设计建立必要的理论基础。

2.1 联邦学习与个性化联邦学习

2.1.1 联邦学习基本框架

联邦学习是一种在多个数据持有方之间实现协同模型训练的分布式机器学习范式，其核心目标是在各参与方不共享原始数据的前提下，通过交换模型参数实现全局模型的优化收敛^[1]。在标准联邦学习框架中，系统由一个中央服务器与若干客户端共同构成。设系统共有 K 个客户端，第 k 个客户端持有私有本地数据集 $\mathcal{D}_k$ ，服务器通过聚合各客户端的本地训练结果来优化如下全局目标函数：

$$\min_{\mathbf{w}} F(\mathbf{w}) = \sum_{k=1}^K p_k F_k(\mathbf{w}), \quad (2.1)$$

其中 $p_k = |\mathcal{D}_k| / \sum_j |\mathcal{D}_j|$ 为第 k 个客户端的聚合权重， $F_k(\mathbf{w})$ 为该客户端在本地数据上的经验损失：

$$F_k(\mathbf{w}) = \frac{1}{|\mathcal{D}_k|} \sum_{(\mathbf{x}, y) \in \mathcal{D}_k} \ell(f(\mathbf{x}; \mathbf{w}), y). \quad (2.2)$$

FedAvg^[1]是目前应用最广泛的联邦学习优化算法。其基本流程为：在第 t 轮通信中，服务器将当前全局模型参数 $\mathbf{w}^t$ 下发至选定的参与客户端；各客户端基于本地数据执行若干轮局部随机梯度下降，得到更新后的本地模型 $\mathbf{w}_k^{t+1}$ ；服务器收集所有参与客户端的本地模型并按样本量权重进行加权平均，得到新的全局模型：

$$\mathbf{w}^{t+1} = \sum_{k \in \mathcal{S}^t} p_k \mathbf{w}_k^{t+1}, \quad (2.3)$$

其中 $\mathcal{S}^t$ 为第 t 轮被选中参与训练的客户端集合。图2.1展示了标准联邦学习的一轮通信流程示意。




图 2.1 标准联邦学习的一轮通信流程示意图。蓝色实线表示服务器向各客户端下发全局模型参数 w^t ，橙色虚线表示各客户端在本地数据上完成若干步梯度更新后将参数 w_k^{t+1} 上传至服务器。服务器按样本量加权执行 FedAvg 聚合，得到新一轮全局模型 w^{t+1} 。原始数据 $\mathcal{D}_k$ 始终保留在客户端本地，不参与任何形式的通信。

从安全视角来看，联邦学习的上述通信机制带来了重要的安全隐患。由于服务器无法直接观测客户端的本地数据与训练过程，只能通过上传的模型参数间接推断客户端行为，恶意客户端可以在不被察觉的情况下对本地训练数据或本地模型参数进行操控，并将含有恶意信息的参数上传至服务器参与聚合，进而将恶意行为注入全局模型。这一“不可见性”是联邦学习中各类攻击行为得以实施的根本前提。

2.1.2 数据异构性与个性化建模

在理想化的 IID 假设下，各客户端的数据分布相同，全局模型对所有客户端均具有良好的适配能力。然而，现实中的联邦学习场景往往远离这一假设。不同客户端在数据采集环境、用户行为习惯、任务目标偏好以及类别覆盖范围等方面均可能存在显著差异，导致各客户端持有的数据在类别分布、特征空间乃至标签定义上呈现出明显的异质性。通常，这种数据异质性主要体现为标签偏移（不同客户端的类别比例不同）、特征偏移（同一类别在不同客户端的表现形式不同）以及数量偏移（各客户端的样本规模差异悬殊）三种形式。在实验设置中，常用 Dirichlet 分布参数 α 来量化

数据异质程度, α 越小则异质性越强, 当 $\alpha \rightarrow \infty$ 时趋近于 IID 分布。

数据异质性给联邦学习带来的最直接后果是客户端漂移 (client drift) 问题: 不同客户端因本地优化目标不同, 其本地梯度方向可能相互冲突, 导致全局模型的收敛速度减慢乃至在某些客户端上表现出明显的性能退化。当 Non-IID 程度较强时, 简单的加权聚合所得的全局模型往往只是对各客户端需求的粗糙折中, 而无法满足每个客户端的实际需求。

值得关注的是, 数据异质性对安全分析同样产生深远影响。在 IID 场景下, 良性客户端的更新围绕同一优化目标波动, 分布较为集中, 异常更新相对容易通过统计手段识别; 而在 Non-IID 场景下, 良性客户端之间的更新分布本就存在较大差异, 恶意更新的“伪装”更为容易, 传统基于更新相似性的检测手段的判别能力因此大幅下降。这一分析也说明, 专门为 Non-IID 场景设计的 PFL 防御方法不能简单套用 IID 场景下的假设。

2.1.3 个性化联邦学习的主要方法

面对数据异质性带来的挑战, 个性化联邦学习的研究者从不同的技术角度出发, 提出了多种解决方案。总体而言, PFL 方法可以归纳为以下几类主要技术路线: 完整模型共享类方法、参数解耦类方法以及基于表示对齐的方法。

完整模型共享类方法保留了全局模型共享的基本框架, 在此基础上通过不同机制引入个性化适配。Per-FedAvg^[4]将模型无关元学习 (MAML) 引入联邦场景, 将全局模型作为元初始化参数, 使各客户端能够通过少量本地梯度步骤快速适配; Ditto^[5]则为每个客户端维护一个独立的个性化模型, 通过正则项约束其与全局模型的偏离程度, 在个性化自由度与联邦协作之间取得平衡; pFedMe 等方法从 Moreau 包络的视角出发, 为每个客户端的个性化目标引入近端正则项。这类方法实现相对简洁, 但在强异质性场景下, 全局模型质量对最终个性化效果的制约较为明显。

参数解耦类方法是近年来 PFL 研究中最活跃的方向之一。该类方法的核心思想是将模型参数分为可在客户端间共享的部分与保留在本地的私有部分, 联邦聚合仅作用于共享参数, 私有参数则根据本地数据独立更新。FedRep^[6]将特征提取器 (表示层) 作为共享部分、分类头作为私有部分, 通过交替优化的方式分别训练两部分参数; FedBN^[7]将批归一化层作为私有层保留在本地, 其余参数参与聚合, 使模型能够对各客户端的特征统计分布进行自适应调整; LG-FedAvg 等方法则探索了在边缘设备侧保留完整网络、仅共享全局特征嵌入的可能性。参数解耦方法在通信效率、训练

稳定性和个性化效果三方面均取得了较好的平衡，是本文 FedCLCM 所采用的基础结构。

基于表示对齐的方法从不同的视角理解个性化，不通过参数层面的解耦，而是通过在客户端间对齐高层表示来缓解异质性。FedProto^[15]提出在客户端间共享类别原型（每类样本的平均特征表示），通过聚合各客户端的类别原型来实现跨客户端的表示空间对齐，避免了直接共享模型参数所带来的分布偏移问题；SCAFFOLD 等方法则通过引入控制变量来修正本地梯度方向，从优化角度缓解客户端漂移。

上述各类方法都将改善 Non-IID 场景下的模型性能作为核心目标，而对安全问题的系统性研究相对较少。图2.2直观展示了参数解耦方法中 base-head 分离结构的具体形式，以及共享参数与私有参数的边界划分。表2.1对主要 PFL 技术路线的特点进行了比较。




图 2.2 个性化联邦学习中的 Base-Head 参数解耦结构示意图。左侧绿色区域为共享特征提取器 (base)，包含若干卷积层和全连接层，其参数 θ_B 由服务器统一聚合与下发，所有客户端共享同一版本；右侧紫色区域为私有分类头 (head)，每个客户端 k 保有各自的 θ_{H_k} ，根据本地数据独立训练，不参与联邦通信。原始输入 x 经 base 映射为 d 维特征表示 z ，再由各客户端的私有 head 完成最终分类预测。

2.2 后门攻击基础

2.2.1 后门攻击的形式化定义

后门攻击是针对机器学习模型训练阶段的一类恶意攻击，攻击目标是在模型中植入一条隐蔽的从特定触发模式到目标标签的映射路径，同时保证模型在普通干净

表 2.1 主流个性化联邦学习方法特点比较

方法类别	代表方法	个性化实现方式	主要特点与局限
完整模型共享	Per-FedAvg、Ditto	元学习初始化、本地正则约束	实现简洁，适用范围广；强异质性地下全局模型质量成瓶颈。
参数解耦	FedRep、FedBN	共享表示层，保留分类头或 BN 层	通信高效，个性化效果好；服务器可观测信息受限，安全分析更复杂。
表示对齐	FedProto、SCAFFOLD	共享原型或修正梯度	避免直接参数共享；依赖表示质量，训练流程较复杂。

样本上维持正常的分类精度，使攻击行为难以通过性能监测被察觉^[16]。

形式化而言，设攻击者的中毒数据集为 $\mathcal{D}_{poison} = \{(\mathbf{x} \oplus \boldsymbol{\delta}, y_t)\}$ ，其中 $\mathbf{x}$ 为原始样本， $\boldsymbol{\delta}$ 为触发器， y_t 为目标标签；干净数据集为 $\mathcal{D}_{clean}$ 。后门训练的优化目标可以写为：

$$\min_{\boldsymbol{\theta}} \sum_{(\mathbf{x}, y) \in \mathcal{D}_{clean}} \mathcal{L}(f(\mathbf{x}; \boldsymbol{\theta}), y) + \lambda \sum_{(\mathbf{x}, y) \in \mathcal{D}_{poison}} \mathcal{L}(f(\mathbf{x} \oplus \boldsymbol{\delta}; \boldsymbol{\theta}), y_t). \quad (2.4)$$

其中 λ 用于平衡主任务损失与后门任务损失的相对权重。通过求解上述优化问题，攻击者希望得到的模型 $f(\cdot; \boldsymbol{\theta}^*)$ 满足：对干净样本输出正确标签，对带触发器的样本输出目标标签 y_t 。

在评价后门攻击效果时，通常关注两个核心指标。一是**主任务精度 (ACC)**，即模型在干净测试集上的分类准确率，反映攻击的隐蔽性；二是**攻击成功率 (ASR)**，即模型在携带触发器的测试样本上将其分类为目标标签的比例，反映后门的有效性。理想的后门攻击应同时实现高 ACC 与高 ASR，即在不影响正常使用的前提下使后门高度可靠地触发。

根据是否修改样本标签，后门攻击还可以分为脏标签攻击 (Dirty-Label Attack) 和净标签攻击 (Clean-Label Attack)。前者同时修改样本内容与标签，后者仅修改样本内容而不修改标签，攻击更为隐蔽但通常需要更强的对样本特征的操控能力。

2.2.2 集中式学习中的典型后门攻击

在集中式深度学习场景中，BadNets^[16]率先提出了一种简单有效的后门攻击方案：在图像样本的固定位置（如右下角）叠加一个小尺寸彩色方块作为触发器，并将对应标签修改为攻击者指定的目标类别。实验表明，即使中毒样本仅占训练数据的极小比例，经过训练的模型也能以极高的成功率在含有该触发器的样本上输出目标标签，同时干净样本上的精度几乎不受影响。BadNets 揭示了深度神经网络对局部特征过拟

合的固有倾向，确立了后门攻击研究的基础范式，此后大量工作在此基础上展开。

为了提升触发器的视觉隐蔽性，Chen 等人提出了 Blended 攻击^[17]，通过将参考图案（如 Hello Kitty 图像）以较低的混合比例与原始样本融合，使触发器在视觉上几乎无法与干净样本区分。Barni 等人提出的 SIG 攻击^[18]则以正弦信号作为触发器，利用频域上的周期性特征进行触发器嵌入，绕过了针对局部像素异常的检测方法。Nguyen 等人提出的 WaNet^[19]更进一步，通过对图像施加随机弹性形变来实现触发器注入，完全绕开了对像素值的直接修改，使触发器几乎无法通过任何像素级分析方法检测。Turner 等人提出的净标签攻击通过对训练样本施加对抗性扰动（而非改变标签），在不改变样本表面语义的前提下植入后门，进一步提升了攻击的隐蔽程度。

上述攻击方法在设计思路各有侧重，但在底层机制上具有共同特点：它们均依赖深度神经网络对训练数据中反复出现的统计规律的高度敏感性，通过在训练数据中系统性地建立触发模式与目标标签之间的共现关系，使模型学习到一条异常的决策捷径。表2.2对集中式场景中的典型触发器设计进行了比较。

表 2.2 集中式学习中典型后门触发器设计方式比较

攻击方法	触发器类型	实现方式	隐蔽性	在 PFL 中的存活性
BadNets	局部图案	固定位置图块叠加	较低，肉眼可见	个性化后易遗忘
Blended	全局叠加	低透明度图案混合	中等	视网络深度而定
SIG	频域信号	正弦信号叠加	较高	视网络深度而定
WaNet	几何变换	弹性图像形变	高	有一定抵抗性
Bad-PFL	自然特征	自编码器提取语义特征	极高	个性化后仍稳定存活

2.2.3 联邦学习中的后门攻击

联邦学习场景为后门攻击的实施提供了更为隐蔽的操作空间。在集中式训练中，模型所有者对训练数据具有完全掌控，可以通过数据清洗或异常检测来防范投毒；而在联邦学习中，服务器对客户端本地数据完全不可见，只能依赖客户端上传的模型参数进行聚合，这给恶意参与者提供了充分的操作余地。

Bagdasaryan 等人提出了模型替换攻击^[2]，这是联邦学习中最具代表性的后门攻击之一。该方法不仅在本地图数据中注入中毒样本，还通过对恶意更新进行线性放大，

使少量恶意客户端的参数在聚合后对全局模型产生超比例的影响。具体地, 设恶意客户端希望将全局模型替换为其本地训练的后门模型 $\mathbf{w}^*$, 则上传参数可设置为:

$$\hat{\mathbf{w}} = \frac{|S^t|}{|\mathcal{A}|} (\mathbf{w}^* - \mathbf{w}^t) + \mathbf{w}^t, \quad (2.5)$$

其中 $\mathcal{A}$ 为恶意客户端集合。这样, 在加权平均后全局模型即被替换为 $\mathbf{w}^*$ (假设全部客户端等权重)。为降低单个更新的异常程度以规避检测, 攻击者还可以通过约束更新幅度的方式使恶意更新更接近良性更新的分布。

DBA^[14]提出了一种协同式的分布式后门攻击, 将完整的触发器模式分解为多个互补的局部子触发器, 分配给不同的恶意客户端各自注入。单独来看, 每个恶意客户端使用的局部触发器并不足以触发完整的后门; 但当多个客户端的更新聚合后, 各局部触发器的影响在全局模型中叠加, 形成完整的后门映射关系。这种分散化的攻击方式使每个恶意客户端的本地更新在统计上更接近良性更新, 从而降低了被鲁棒聚合等方法检测到的概率。

随着防御技术的进步, 后门攻击方法也在不断演化, 逐步转向以最小化恶意更新与良性更新之间的统计差异为优化目标, 以提高在有防御存在情况下的攻击成功率。

2.2.4 个性化联邦学习中后门攻击的特殊性

相较于传统联邦学习, PFL 中的后门问题呈现出若干独特之处, 值得深入分析。

首先是个性化机制对后门效果的双重影响。一方面, 本地个性化训练通过在本地产干净数据上对共享模型进行再适配, 可能削弱来自恶意共享参数的后门特征, 这为部分研究者提供了将个性化视为一种天然防御手段的依据; 另一方面, 这种削弱效果并不稳定, 高度依赖于模型结构、触发器设计以及本地数据规模。Qin 等人的研究^[8]系统考察了多种主流 PFL 算法对后门攻击的抵抗能力, 发现在浅层 CNN 上个性化机制确实能够有效降低攻击成功率, 但在采用 ResNet 等深层架构时, 攻击成功率仍然较高, 表明“个性化天然防御后门”的论断在实际中并不成立。

其次是触发器存活性问题。触发器能否在个性化训练后得以保留, 是决定 PFL 后门攻击有效性的关键因素。Lyu 等人^[9]对这一问题进行了系统分析, 指出当攻击者通过特殊设计使后门任务与主任务在梯度方向上保持相近时, 本地个性化训练对后门的削弱效果会大幅减弱, 甚至可以在多轮 PFL 训练后仍然维持较高的攻击成功率。Fan 等人提出的 Bad-PFL^[10]则从触发器设计的根本上解决了这一问题: 传统手工触发器(如固定图块、叠加图案等)与正常样本的特征分布存在明显差异, 本地重训练会将这种差异作为噪声加以消除; 而若以自编码器从自然样本中提取语义特征作为触

发载体，后门特征与主任务特征在特征空间中高度重叠，使得个性化训练后后门依然稳定存活。这一研究标志着 PFL 后门攻击从“信号注入”向“特征绑定”的重要演化。

再次是参数解耦结构带来的攻击面变化。在 base-head 分离的 PFL 框架中，攻击者通过污染共享 base 参数，即可对所有良性客户端的个性化模型产生影响，因为所有客户端的个性化 head 都是在同一个全局 base 上训练的。这意味着，即使恶意客户端的数量极少，只要其上传的恶意 base 参数在聚合后被下发至所有客户端，后门便可随个性化训练在整个系统中扩散。对防御者而言，服务器只能观测 base 参数的更新，无法感知各客户端私有 head 的训练情况，信息的部分可见性进一步增加了防御的难度。

上述分析共同指向了 PFL 后门防御面临的核心挑战：如何在信息不完整、数据异构性强的条件下，设计既能有效抑制后门传播又不过度损害个性化性能的防御机制。

2.3 联邦学习后门防御方法

2.3.1 基于鲁棒聚合的服务器端防御

服务器端鲁棒聚合方法是联邦后门防御研究中发展最早、应用最广的一类方法，其核心思想是在聚合阶段通过对客户端更新的统计筛选来降低恶意更新的影响。

Blanchard 等人提出的 Krum^[11]算法基于“多数诚实”假设：在所有客户端的更新中，诚实客户端的更新彼此相近，而恶意客户端的更新则偏离这一集中区域。Krum 通过计算每个更新与其最近邻更新之间的欧氏距离总和来为每个客户端打分，选取得分最低（即与多数更新最为接近）的 m 个更新参与聚合。

Yin 等人提出了基于统计截断的鲁棒聚合策略^[12]。其中，Trimmed Mean 方法在每个参数维度上对所有客户端的参数值进行排序，剔除最大和最小各 β 比例的极端值，对剩余值取均值作为聚合结果：

$$w^{t+1}[d] = \frac{1}{K - 2\lfloor \beta K \rfloor} \sum_{k=\lfloor \beta K \rfloor+1}^{K-\lfloor \beta K \rfloor} \text{sort}(\{w_k^{t+1}[d]\}_{k=1}^K), \quad (2.6)$$

其中 d 表示参数索引。Coordinate-wise Median 方法则直接取每个参数维度上所有客户端参数值的中位数。这两种方法的统计理论保证较为完备，在攻击者数量不超过一定比例时具有可证的拜占庭鲁棒性。

然而，上述方法均建立在良性客户端更新具有较强统计一致性的假设之上。在

IID 或弱异构场景中, 这一假设基本成立; 但在 PFL 的强 Non-IID 场景中, 数据异质性引发的良性更新多样性使得恶意更新难以仅凭统计特征加以区分。此外, 以整层参数为单位进行截断的粗粒度处理方式, 可能将后门实际只影响少数通道的结构性问题简单化, 在非均匀分布的情形下容易出现误截断, 进而损害系统的个性化性能。

2.3.2 基于异常检测与过滤的防御

异常检测与过滤类方法尝试在聚合前对客户端上传的更新进行分析, 以识别和排除可能的恶意更新。这类方法通常利用恶意更新与良性更新在某种特征空间上的统计差异来构建检测准则。

FoolsGold^[13]针对多个恶意客户端提交高度相似的中毒更新这一协同攻击特征, 设计了基于历史相似度的权重衰减机制: 在多轮训练中, 若某客户端的更新与其他客户端保持高度相似, 则降低其在聚合中的权重, 以此抑制可能的协同攻击行为。该方法在恶意客户端采取简单数据投毒策略时具有一定效果, 但当攻击者主动在各个恶意客户端之间增加更新多样性时, 该方法的检测效果会显著下降。

其他研究尝试利用聚类、降维或矩阵分解等技术分析客户端更新的分布结构, 以期发现其中的异常模式。但这些方法的共同局限在于, 当良性更新本身就具有较高多样性时 (如 PFL 中的 Non-IID 场景), 基于分布差异的异常判断本身就缺乏可靠的判别基础, 误报率往往较高。

2.3.3 基于模型净化的防御

模型净化类方法不对客户端更新进行逐轮筛选, 而是默认聚合后的全局模型可能已受到污染, 通过专门的后处理步骤来消除后门效应。Zhang 等人提出的 FLPurifier^[20]将对对比学习的思想引入联邦后门防御, 通过区分与触发器相关的特征路径和与正常语义相关的特征路径, 在不依赖触发器形态先验的前提下对模型进行净化。这类方法通常需要一定量的干净辅助数据, 在辅助数据可用时往往能够取得较好的净化效果; 但在联邦学习场景中, 服务器或客户端通常不持有与训练数据分布相近的干净辅助数据, 这在一定程度上限制了该类方法的实际可用性。此外, 针对整个全局模型进行净化的操作代价相对较高, 且在 PFL 场景中需要同时处理多个差异化的个性化模型, 进一步增加了复杂度。

2.3.4 现有防御方法在 PFL 场景中的局限性

综合对上述三类方法的分析，不难发现它们在 PFL 场景中均面临若干共性局限，如表2.3所示。

第一，鲁棒聚合和异常检测方法的设计前提与 PFL 的数据异构性存在根本性冲突。前者依赖良性更新的统计一致性，而 PFL 场景中良性更新的多样性与异质性恰好是系统正常运行的体现。将这种正常差异误判为恶意行为，会在抑制攻击的同时严重损伤系统的个性化能力。

第二，上述方法均以服务器端的统一判断为核心，忽视了 PFL 中客户端侧本地训练过程的重要作用。在 base-head 分离框架下，即便服务器在聚合阶段识别并过滤了恶意更新，仍无法阻止已经进入良性客户端本地模型的后门特征在个性化训练中被进一步强化；而完全依赖客户端侧的净化方法又因资源限制和数据不足而难以独立完成稳定可靠的后门消除。

第三，以整层或整客户端为粒度的防御方式与后门在模型内部的精细结构（通道集中性）不匹配，导致防御精度不足、对正常更新的误伤程度偏高。

表 2.3 联邦后门防御方法在 PFL 场景中的局限性比较

防御类型	代表方法	主要优势	在 PFL 场景中的主要局限
鲁棒聚合	Krum、Trimmed Mean、Bulyan	无需辅助数据，服务器侧统一实施	依赖良性更新一致性，Non-IID 下误判率高；粒度粗放，易损个性化性能。
异常检测	FoolsGold、聚类检测	可在聚合前过滤可疑更新	攻击者可通过增加多样性规避；良性更新多样性模糊了判别边界。
模型净化	FLPurifier、剪枝微调	对已污染模型具有补救作用	通常依赖辅助数据；PFL 中需处理多个个性化模型，复杂度高。

2.4 对抗训练与后门净化的关联

对抗训练（Adversarial Training）最初作为提升模型对抗样本鲁棒性的手段而被提出，其基本形式是在训练过程中显式地针对最坏情况的输入扰动进行优化：

$$\min_{\theta} \mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\max_{\|\delta\| \leq \epsilon} \mathcal{L}(f(x + \delta; \theta), y) \right]. \quad (2.7)$$

通过在训练中反复暴露模型对最强扰动的脆弱性并进行修正，对抗训练能够减少模型对局部不稳定特征的依赖，从而提升其在扰动输入下的预测一致性。

从机理上看，对抗训练与后门防御之间存在深刻的内在关联。后门攻击得以成功的根本原因在于，深度神经网络倾向于学习训练数据中反复出现的统计捷径：触发器之所以能够在训练完成后稳定激活后门行为，是因为模型对触发器模式形成了高度的特征敏感性。对抗训练通过迫使模型在输入扰动下保持预测稳定，恰好可以削弱这种对局部特定模式的过度敏感性。Mu 等人的研究^[2]发现，在受后门污染的模型上，对抗样本与后门触发样本往往激活相似的神经元通路，这一现象表明两者在特征利用机制上存在深层共性，也为利用对抗样本净化后门提供了理论依据。

在对抗样本生成方法中，PGD (Projected Gradient Descent)^[21]通过在扰动约束范围内执行多步迭代梯度上升，能够生成比 FGSM (Fast Gradient Sign Method) 更强的对抗扰动：

$$\mathbf{x}^{(t+1)} = \Pi_{\mathcal{B}_\epsilon(\mathbf{x})} \left(\mathbf{x}^{(t)} + \alpha \cdot \text{sign} \left(\nabla_{\mathbf{x}} \mathcal{L}(f(\mathbf{x}^{(t)}; \theta), y) \right) \right), \quad (2.8)$$

其中 $\Pi_{\mathcal{B}_\epsilon(\mathbf{x})}$ 表示投影到以 $\mathbf{x}$ 为中心、半径为 ϵ 的扰动球内的操作。较强的对抗扰动在“压力测试”中更能暴露模型的脆弱路径，因而在后门净化场景中比单步方法具有更强的效果。

然而，将对抗训练直接应用于后门防御也存在明显的局限性：若扰动预算 ϵ 设置过大，对抗训练可能损伤模型对正常局部特征的表达能力，导致主任务精度下降；在本地数据规模有限的客户端侧，强度较大的对抗微调对个性化性能的负面影响更为显著。因此，本文在客户端侧并未采用完整的对抗训练框架，而是借鉴其“暴露并抑制局部脆弱特征”的核心思想，以代价更低的触发器破坏型增强和轻量一致性约束来实现更有针对性的共享表示净化，在防御效果与个性化性能之间寻求更好的平衡。

2.5 本章小结

本章对 FedCLCM 研究所涉及的核心理论基础进行了系统梳理，主要结论如下。

(1) 联邦学习的分布式训练机制赋予了恶意参与者对后门攻击的隐蔽实施空间，而数据的非独立同分布特性则进一步削弱了传统检测方法在 PFL 场景中的有效性。

(2) PFL 中的后门攻击呈现出与传统 FL 不同的特殊性，包括触发器存活性与个性化过程的交互、base-head 分离结构带来的攻击面变化，以及后门攻击从“信号注入”向“特征绑定”的演化趋势。

(3) 现有联邦后门防御方法在 PFL 场景中的适用性均受到不同程度的限制，主

要体现在方法假设与数据异构性的冲突、单侧防御的信息盲区以及粗粒度处理方式与后门结构特征的失配三个方面。

(4) 对抗训练为后门净化提供了机理上的支撑，但直接应用存在代价偏高的问题；轻量化的触发器破坏型增强结合特征一致性约束，是在 PFL 资源约束下实现客户端侧鲁棒性增强的更合适选择。

上述分析为第三章 FedCLCM 方法的设计提供了充分的理论依据，明确了各防御模块的设计动机与技术取舍。

第3章 FedCLCM: 面向个性化联邦学习的协同后门防御方法

3.1 引言

第二章的分析表明, PFL 后门防御面临的核心困难可以从三个层面加以描述。在方法假设层面, 现有鲁棒聚合等防御方法依赖良性客户端更新的统计一致性, 而这一前提在 Non-IID 的 PFL 场景中无法成立, 使得传统方法在抑制恶意更新的同时对正常个性化更新造成不必要的误伤。在防御覆盖层面, 服务器端方法对客户端侧的本地训练过程不可见, 客户端侧方法又受到算力和本地数据规模的制约, 单侧防御均无法覆盖从本地训练到全局聚合的完整后门传播链路。在防御粒度层面, 后门触发器在模型内部通常集中影响少数特定输出通道, 以整层参数为单位的粗粒度处理方式与这一结构特征不匹配, 在精度和效率两方面均存在不足。

为系统应对上述三方面困难, 本章提出 FedCLCM (Federated Contrastive Learning & Channel Masking) 防御框架。FedCLCM 的核心设计思路是: 在客户端侧通过触发器破坏型增强与特征一致性约束, 主动降低共享表示对触发模式的敏感性; 在服务器端通过通道方差评分生成软掩码, 配合修剪均值聚合在两个粒度上协同抑制恶意通道的传播影响; 客户端侧与服务器端的防御机制相互配合, 共同覆盖后门传播的完整链路, 且全程无需辅助数据和触发器先验知识。

本章其余部分的组织结构如下: 第3.2节给出问题的形式化定义, 包括系统模型、威胁模型与防御目标; 第3.3节介绍 FedCLCM 的总体设计框架; 第3.4节详细阐述客户端侧的鲁棒个性化训练机制; 第3.5节详细阐述服务器端的通道感知修剪聚合机制; 第3.6节对方法的关键性质进行理论分析; 第3.7节给出本章小结。

3.2 问题定义

3.2.1 系统模型

本文考虑一个由中央服务器与 N 个客户端共同构成的个性化联邦学习系统, 客户端集合记为 $\mathcal{U} = \{1, 2, \dots, N\}$ 。第 i 个客户端持有本地私有数据集

$$\mathcal{D}_i = \{(\mathbf{x}_{i,j}, y_{i,j})\}_{j=1}^{m_i}, \quad \mathbf{x}_{i,j} \in \mathcal{X}, y_{i,j} \in \mathcal{Y}, \quad (3.1)$$

其中 $n_i = |\mathcal{D}_i|$ 为该客户端的样本总数。系统满足典型的 Non-IID 假设, 即不同客户端的数据分布 $P_i(\mathbf{x}, y)$ 一般不相同。

在模型结构上, 本文采用 base-head 分离的个性化联邦学习框架, 将模型拆分为在所有客户端间共享的特征提取器 (base) 和各客户端私有的分类头 (head) 两部分。具体地, 记共享特征提取器为

$$B(\cdot; \theta_B) : \mathcal{X} \rightarrow \mathbb{R}^d, \quad (3.2)$$

其中 θ_B 为共享参数, 由服务器负责聚合与下发; 记客户端 i 的私有分类头为

$$H_i(\cdot; \theta_{H_i}) : \mathbb{R}^d \rightarrow \mathcal{Y}, \quad (3.3)$$

其中 θ_{H_i} 仅在客户端 i 本地保留和更新, 不参与联邦通信。客户端 i 的完整个性化模型表示为两部分的组合:

$$f_i(\mathbf{x}) = H_i(B(\mathbf{x}; \theta_B); \theta_{H_i}). \quad (3.4)$$

在第 t 轮通信中, 服务器从客户端集合 $\mathcal{U}$ 中选取子集 $\mathcal{S}'$ 参与本轮训练, 向其下发当前全局共享参数 θ_B^t 。被选客户端在本地完成训练后, 仅将更新后的 base 参数 $\theta_{B,i}^{t+1}$ 上传至服务器, 由服务器执行聚合得到 θ_B^{t+1} 后进入下一轮。私有 head 参数 θ_{H_i} 不参与任何形式的联邦通信, 始终保留在客户端本地。

3.2.2 威胁模型

本文考虑的攻击场景为: 系统中的部分客户端被攻击者控制, 成为恶意参与者。设恶意客户端集合为 $\mathcal{A} \subset \mathcal{U}$, 其规模满足 $|\mathcal{A}| = C \ll N$, 即攻击者仅控制少数客户端。诚实客户端集合定义为 $\mathcal{H} = \mathcal{U} \setminus \mathcal{A}$ 。

在攻击能力方面, 恶意客户端完全掌控自身的本地训练数据、训练过程和模型参数, 可以在本地数据中以任意方式注入中毒样本, 也可以对本地训练损失函数和优化过程进行任意修改, 或在上传前对参数进行任意变换。恶意客户端还能够获取每轮服务器下发的全局 base 参数 θ_B^t , 据此调整其攻击策略。但攻击者不能直接访问其他诚实客户端的私有数据和 head 参数, 也不能干预服务器的聚合过程。

在攻击目标方面, 恶意客户端希望达成两个互相配合的目标: 一是使诚实客户端最终得到的个性化模型在干净样本上维持较高的分类精度, 以此保证攻击的隐蔽性; 二是使这些模型在输入含有特定触发器的样本时以较高概率输出攻击者预设的目标标签, 以此达到后门攻击的目的。第一个目标是第二个目标成立的前提条件——只有

当攻击在日常使用中不引发可察觉的性能异常，后门才能在系统部署后长期保持活跃。

3.2.3 防御目标

FedCLCM 旨在在上述威胁场景下，实现以下防御目标。

防御有效性：显著降低诚实客户端个性化模型上的攻击成功率（ASR），使其接近无攻击时的基准水平，从而消除或大幅削弱后门攻击的威胁。

性能保持：在实施防御的同时，尽量保持诚实客户端个性化模型在干净测试样本上的主任务准确率（ACC），控制防御操作对正常个性化能力的影响在可接受范围内。

无先验依赖：防御方法不依赖于触发器的具体形态（如位置、大小、颜色、图案类型等）、攻击者的身份信息、服务器端的辅助数据或其他形式的额外监督信息，仅利用常规联邦学习框架下已有的信息完成防御。

计算可行：方法引入的额外计算和通信开销应在可控范围内，能够无缝嵌入现有的 PFL 训练框架，不显著增加系统的部署复杂度。

3.3 FedCLCM 总体框架

3.3.1 设计思路

FedCLCM 的设计以对后门攻击在 PFL 中的传播机制的分析为出发点。通过分析可以发现，后门的完整传播路径由两个阶段构成：在本地训练阶段，恶意客户端通过污染本地数据使 base 模型建立触发模式与目标标签之间的关联，形成含后门的 base 参数；在聚合传播阶段，含后门的 base 参数经服务器聚合后下发至所有诚实客户端，诚实客户端在此基础上进行本地个性化训练时可能将后门特征纳入其个性化模型。

针对这两个阶段，FedCLCM 采取了对应的防御策略。对于本地训练阶段，FedCLCM 在诚实客户端引入触发器破坏型增强和特征一致性约束，从训练的角度主动降低 base 对局部触发模式的敏感性，使后门特征在诚实客户端的共享表示中难以被有效记忆。对于聚合传播阶段，FedCLCM 在服务器端通过通道方差统计识别可疑通道，以软掩码配合修剪均值聚合，在细粒度上抑制恶意通道对全局模型的污染。

这两层防御机制在作用对象（诚实客户端的 base 训练 vs. 服务器端的 base 聚合）和作用方式（减少写入 vs. 降低扩散）上形成互补，共同覆盖了后门传播的完整链路，其协同关系如图3.1所示。




图 3.1 FedCLCM 完整系统架构图。左侧绿色区域为诚实客户端 (以 i_1, i_2 为例), 每个客户端的本地训练流程依次为: 触发器破坏型增强 $\mathcal{A}_{tb}$ 、双视图生成 ($x^{(1)}, x^{(2)}$)、共享 base 特征提取、特征一致性损失 $\mathcal{L}_{cl}$ 计算, 最终以 $\mathcal{L}_{base} = \mathcal{L}_{ce} + \lambda_{cl} \mathcal{L}_{cl}$ 为目标更新共享 base 参数; 右侧蓝色区域为中央服务器, 依序执行四步: 计算各层通道更新量 $\Delta_i^{t,l}$ 、通道方差评分 $v_c^{t,l}$ 、生成软掩码 $M^{t,l}$ 、修剪均值聚合输出全局参数 θ_B^{t+1} ; 下方红色区域为恶意客户端, 上传含后门的参数。蓝色实线表示下发, 绿色虚线表示诚实上传, 红色虚线表示恶意的上传。

3.3.2 方法组成

FedCLCM 由以下三个相互衔接的核心组成部分构成。

两阶段交替训练骨架。在继承 FedRep 基本结构^[6]的基础上, FedCLCM 以交替优化的方式分别训练分类头和共享 base, 为客户端侧防御机制提供嵌入点。每轮本地训练先冻结 base 更新 head, 再冻结 head 更新 base, 两阶段均启用触发器破坏型增强。

触发器破坏型增强与特征一致性约束 (客户端侧)。触发器破坏型增强通过在输入样本的随机局部区域执行噪声填充, 系统性地打断模型对局部固定触发模式的稳定记忆。特征一致性约束在此基础上进一步构造两路高斯扰动视图, 通过要求 base 在两路视图上输出接近的特征表示, 引导 base 向语义稳定的方向收敛, 从而在不依赖触发器先验的前提下主动降低后门特征的可学习性。

通道方差感知软掩码与修剪均值协同聚合 (服务器端)。服务器在每轮聚合前统计各卷积层输出通道在不同客户端间的更新方差, 以此为评分依据识别可能承载后门特征的高方差通道, 并对每个客户端上传的 base 参数中的这些通道施加软降权 (掩码系数小于 1)。经掩码处理后的参数再执行修剪均值聚合, 通过排序截断进一步剔除极端更新值, 实现通道级与客户端级的双重异常抑制。

3.3.3 整体流程

算法3.1以伪代码形式给出了 FedCLCM 完整训练流程的概要。在第 t 轮通信中, 流程主要包括: 服务器下发 base 参数、客户端执行两阶段交替训练 (诚实客户端启用防御机制)、服务器收集 base 参数更新并执行通道方差评分与软掩码生成、最后执行修剪均值聚合。

3.4 客户端侧鲁棒个性化训练

3.4.1 两阶段交替训练

FedCLCM 的客户端侧训练延续了 FedRep^[6]的两阶段交替优化思路, 在每轮本地训练中先更新分类头、再更新共享 base, 两阶段所用损失函数的设计各有侧重, 共同服务于后门防御目标。

第一阶段 (分类头更新, 共 E_h 步): 冻结当前共享 base 参数 θ_B^t 不更新, 对分类头 θ_{H_i} 进行优化:

$$\theta_{H_i}^{t+\frac{1}{2}} = \arg \min_{\theta_{H_i}} \frac{1}{n_i} \sum_{(x,y) \in \mathcal{D}_i} \mathcal{L}(H_i(B(\tilde{x}; \theta_B^t); \theta_{H_i}), y), \quad (3.5)$$

算法 3.1 FedCLCM 整体训练流程（概要）

Input: 总客户端数 N , 恶意客户端数 C , 总通信轮数 T , 各轮参与率 r

```

1 随机初始化全局 base 参数  $\theta_B^0$ , 各客户端 head 参数  $\{\theta_{H_i}^0\}$ ;
2 for  $t = 0, 1, \dots, T - 1$  do
3   服务器随机选取  $|S'| = \lceil rN \rceil$  个客户端组成  $S'$ , 下发  $\theta_B^t$ ;
4   foreach 客户端  $i \in S'$  (并行) do
5     if  $i \in \mathcal{H}$  (诚实客户端) then
6       | 调用算法3.2, 启用触发破坏增强与一致性约束;
7     else
8       | 执行恶意本地训练 (含后门数据投毒);
9     | 上传更新后的  $\theta_{B,i}^{t+1}$ ;
10  if  $t > 0$  then
11    | 调用算法3.3, 执行通道方差评分、软掩码生成与修剪均值聚合;
12  else
13    | 对  $\{\theta_{B,i}^{t+1}\}$  执行标准加权平均, 得  $\theta_B^{t+1}$ ;

```

其中 $\tilde{\mathbf{x}} = \mathcal{A}_{tb}(\mathbf{x})$ 表示经过触发器破坏型增强处理的样本（详见下文）， $\mathcal{L}$ 为交叉熵损失。先更新分类头的好处在于，使分类头先基于当前共享表示建立稳定的本地决策边界，避免在 base 和 head 同时更新时两者之间产生优化干扰，提升训练的稳定性。

第二阶段（共享 base 更新，共 E_b 步）：固定第一阶段更新后的分类头参数 $\theta_{H_i}^{t+\frac{1}{2}}$ ，对共享 base 参数进行优化：

$$\theta_{B,i}^{t+1} = \arg \min_{\theta_B} \mathcal{L}_{base}^{(i)}(\theta_B), \quad (3.6)$$

其中 $\mathcal{L}_{base}^{(i)}$ 为诚实客户端在第二阶段的训练目标，包含分类损失与特征一致性约束两部分，具体形式将在第3.4.4节给出。

3.4.2 触发器破坏型增强

触发器破坏型增强的设计动机来自对后门触发机制的分析。绝大多数后门触发器——无论是固定位置的图案叠加、正弦信号叠加，还是弹性形变——之所以能够在训练后稳定地激活后门行为，根本原因在于模型在训练数据中反复见到触发器与目标标签的共现，并对其形成了稳定的局部特征依赖。如果能够在训练过程中系统性地破坏触发器形态的可复现性，使模型无法稳定地将局部触发特征与目标类别建立关联，后门便难以被有效嵌入。

基于这一思路，本文定义触发器破坏型增强算子 $\mathcal{A}_{tb}(\cdot)$ 。给定输入样本 $\mathbf{x} \in$

$[-1, 1]^{C \times H \times W}$, 增强强度参数为 $s > 0$ (默认 $s = 0.1$), 增强过程如下: 以概率

$$p_{erase} = \min(0.6, 2s) \quad (3.7)$$

决定是否执行局部区域擦除。若决定擦除, 则在图像内随机确定一个矩形区域 Ω , 其面积与图像总面积之比 $r = |\Omega|/(H \times W)$ 在区间 $[r_{min}, r_{max}]$ 内均匀采样, 其中

$$r_{min} = 0.05, \quad r_{max} = \min(0.35, 0.05 + 1.5s). \quad (3.8)$$

在所选区域 Ω 内, 以均匀随机噪声 $\xi \sim \mathcal{U}(-1, 1)$ 替换原始像素, 得到增强样本:

$$\tilde{\mathbf{x}} = \mathcal{A}_{tb}(\mathbf{x}) = (1 - \mathbf{M}_\Omega) \odot \mathbf{x} + \mathbf{M}_\Omega \odot \xi, \quad (3.9)$$

其中 $\mathbf{M}_\Omega$ 为区域 Ω 对应的二值掩码。

这一增强操作有两层作用。其一, 随机位置和随机大小的擦除区域使模型在训练中无法对任何特定局部位置建立稳定的特征依赖, 从而系统性地干扰触发器所在区域的可感知性; 其二, 以随机噪声填充而非简单清零或均值填充, 可以避免特征空间出现明显的分布异常, 使增强样本在分布上更接近正常样本, 减少对主任务学习的不必要干扰。触发器破坏型增强在两阶段训练中均被启用, 确保分类头和 base 的训练都不依赖于局部固定的触发模式。

3.4.3 双视图特征一致性约束

触发器破坏型增强在输入层面破坏了触发模式的稳定性, 但仍缺乏一个显式的约束来引导 base 学习对轻微局部扰动具有语义稳定性的特征表示。为此, FedCLCM 在 base 训练阶段额外引入了双视图特征一致性约束。

具体地, 在每个训练步骤中, 首先对当前小批量样本执行触发器破坏型增强, 得到增强样本 $\tilde{\mathbf{x}} = \mathcal{A}_{tb}(\mathbf{x})$ 。在此基础上, 通过对 $\tilde{\mathbf{x}}$ 分别叠加两次独立采样的高斯噪声, 生成两路随机扰动视图:

$$\mathbf{x}^{(1)} = \text{clip}(\tilde{\mathbf{x}} + \boldsymbol{\varepsilon}_1, -1, 1), \quad \mathbf{x}^{(2)} = \text{clip}(\tilde{\mathbf{x}} + \boldsymbol{\varepsilon}_2, -1, 1), \quad \boldsymbol{\varepsilon}_1, \boldsymbol{\varepsilon}_2 \sim \mathcal{N}(\mathbf{0}, s^2 \mathbf{I}). \quad (3.10)$$

两路视图分别通过共享 base 网络, 得到对应的特征表示:

$$\mathbf{h}^{(1)} = B(\mathbf{x}^{(1)}; \boldsymbol{\theta}_B), \quad \mathbf{h}^{(2)} = B(\mathbf{x}^{(2)}; \boldsymbol{\theta}_B). \quad (3.11)$$

特征一致性损失定义为两路表示之间的均方误差:

$$\mathcal{L}_{cl} = \frac{1}{d} \|\mathbf{h}^{(1)} - \mathbf{h}^{(2)}\|_2^2, \quad (3.12)$$

其中 d 为特征维度。最小化 $\mathcal{L}_{cl}$ 要求 **base** 在面对来自同一样本的两路轻微扰动时输出尽可能接近的特征表示，即对局部细微变化具有稳健性。

理解这一约束的关键在于区分两类特征：依赖于稳定语义结构的特征，在经过局部擦除和高斯噪声的双重扰动后，其在 **base** 中激活的表示仍能保持相近；而仅依赖于某一局部脆弱结构（如触发器图案）的特征，在局部擦除后其结构已被破坏，两路视图上的特征表示将无法保持一致。通过持续最小化 $\mathcal{L}_{cl}$ ，**base** 被引导向前一类特征靠拢，远离后一类特征，从而在不依赖触发器知识的前提下减少后门特征在共享表示中被持续强化的概率。

需要特别指出的是，两路视图均从已经过触发器破坏型增强的 $\tilde{\mathbf{x}}$ 生成，而非从原始样本 $\mathbf{x}$ 生成。这一设计使得一致性约束工作在触发模式已被部分破坏的基础之上，进一步提高了对触发特征的针对性。此外，本文所采用的一致性约束不引入负样本项，不需要大批量训练或额外投影头，其实现代价远低于完整的对比学习框架，更适合在资源受限的客户端侧嵌入使用。

3.4.4 客户端本地目标函数

综合以上机制，FedCLCM 在诚实客户端上的两阶段本地训练目标如下。

第一阶段（分类头更新）的损失函数为：

$$\mathcal{L}_{head}^{(i)} = \frac{1}{n_i} \sum_{(\mathbf{x}, y) \in \mathcal{D}_i} \mathcal{L}(f_i(\mathcal{A}_{tb}(\mathbf{x})), y). \quad (3.13)$$

第二阶段（共享 **base 更新）**的损失函数由分类损失与一致性约束两部分组成：

$$\mathcal{L}_{base}^{(i)} = \mathcal{L}_{ce}^{(i)} + \lambda_{cl} \cdot \mathcal{L}_{cl}^{(i)}, \quad (3.14)$$

其中分类损失 $\mathcal{L}_{ce}^{(i)}$ 使用触发器破坏型增强后的样本计算：

$$\mathcal{L}_{ce}^{(i)} = \frac{1}{n_i} \sum_{(\mathbf{x}, y) \in \mathcal{D}_i} \mathcal{L}(f_i(\mathcal{A}_{tb}(\mathbf{x})), y), \quad (3.15)$$

特征一致性损失 $\mathcal{L}_{cl}^{(i)}$ 则使用从增强样本生成的双视图计算（见公式(3.12)）， λ_{cl} 为一致性约束的权重超参数（默认 $\lambda_{cl} = 0.5$ ）。对于恶意客户端，其本地训练目标不受上述约束，可以使用包含后门样本的本地数据以任意方式定义训练损失。

3.4.5 客户端侧训练算法

算法3.2给出了 FedCLCM 在诚实客户端侧的详细训练流程。

算法 3.2 FedCLCM 诚实客户端本地训练

Input: 全局 base 参数 θ_B^t , 本地 head 参数 $\theta_{H_i}^t$, 本地数据集 $\mathcal{D}_i$, head 训练步数 E_h , base 训练步数 E_b , 增强强度 s , 一致性权重 λ_{cl}

Output: 上传 base 参数 $\theta_{B,i}^{t+1}$, 更新后 head 参数 $\theta_{H_i}^{t+1}$

- 1 接收 θ_B^t , 与本地 $\theta_{H_i}^t$ 组合为个性化模型 f_i ;
// 第一阶段: 冻结 base, 更新 head
- 2 冻结 θ_B^t ;
- 3 **for** $e = 1, \dots, E_h$ **do**
- 4 采样小批量 $(\mathbf{x}, y) \sim \mathcal{D}_i$;
- 5 计算 $\tilde{\mathbf{x}} \leftarrow \mathcal{A}_{tb}(\mathbf{x}; s)$;
- 6 计算 $\mathcal{L}_{head}^{(i)} = \mathcal{L}(f_i(\tilde{\mathbf{x}}), y)$, 更新 θ_{H_i} ;
- 7 记更新后的 head 为 $\theta_{H_i}^{t+\frac{1}{2}}$;
// 第二阶段: 固定 head, 更新 base
- 8 固定 $\theta_{H_i}^{t+\frac{1}{2}}$, 解冻 θ_B ;
- 9 **for** $e = 1, \dots, E_b$ **do**
- 10 采样小批量 $(\mathbf{x}, y) \sim \mathcal{D}_i$;
- 11 计算 $\tilde{\mathbf{x}} \leftarrow \mathcal{A}_{tb}(\mathbf{x}; s)$;
- 12 生成两路视图: $\mathbf{x}^{(1)} \leftarrow \text{clip}(\tilde{\mathbf{x}} + \boldsymbol{\varepsilon}_1, -1, 1)$, $\mathbf{x}^{(2)} \leftarrow \text{clip}(\tilde{\mathbf{x}} + \boldsymbol{\varepsilon}_2, -1, 1)$,
 $\boldsymbol{\varepsilon}_1, \boldsymbol{\varepsilon}_2 \sim \mathcal{N}(\mathbf{0}, s^2 \mathbf{I})$;
- 13 计算特征: $\mathbf{h}^{(1)} \leftarrow B(\mathbf{x}^{(1)}; \theta_B)$, $\mathbf{h}^{(2)} \leftarrow B(\mathbf{x}^{(2)}; \theta_B)$;
- 14 计算 $\mathcal{L}_{cl} \leftarrow \frac{1}{d} \|\mathbf{h}^{(1)} - \mathbf{h}^{(2)}\|_2^2$;
- 15 计算 $\mathcal{L}_{ce} \leftarrow \mathcal{L}(f_i(\tilde{\mathbf{x}}), y)$;
- 16 以 $\mathcal{L}_{ce} + \lambda_{cl} \mathcal{L}_{cl}$ 为损失, 更新 θ_B ;
- 17 仅上传 $\theta_{B,i}^{t+1}$ 至服务器, 本地保留 $\theta_{H_i}^{t+1}$;

3.5 服务器端通道感知修剪聚合

3.5.1 通道方差建模

在第 t 轮通信结束后, 服务器收到本轮所有被选客户端上传的 base 参数 $\{\theta_{B,i}^{t+1}\}_{i \in S^t}$ 。服务器还保存有上一轮的全局 base 参数 θ_B^t (在首轮时无此历史记录, 直接执行标准加权平均)。为了从这些上传参数中识别可能承载后门特征的异常通道, 服务器首先计算各客户端相对于上一轮全局参数的更新量:

$$\Delta_i^{t,l} = \theta_{B,i}^{t+1,l} - \theta_B^{t,l}, \quad (3.16)$$

其中 l 表示 base 网络中第 l 个卷积层 (仅对 4 维权重张量计算, 即仅处理卷积权重而非偏置)。

通道方差建模的核心依据是: 后门触发器在模型内部并非均匀地影响所有参数, 而是倾向于集中激活少数特定输出通道。恶意客户端为了在这些通道中建立触发器

与目标标签之间的关联，会在对应通道的参数上产生与良性客户端明显不同的更新模式，从而导致这些通道在跨客户端维度上的更新方差显著高于其他通道。基于这一观察，可以利用通道级更新方差作为检测后门相关通道的统计信号。

设第 l 层输出通道总数为 C_l ，第 c 个输出通道对应的参数位置集合为 Ω_c^l （即该输出通道的所有滤波器权重）。则该通道的跨客户端平均更新方差定义为：

$$v_c^{t,l} = \frac{1}{|\Omega_c^l|} \sum_{u \in \Omega_c^l} \text{Var}_{i \in S^t} \left(\Delta_{i,u}^{t,l} \right), \quad (3.17)$$

其中 $\Delta_{i,u}^{t,l}$ 表示客户端 i 在层 l 通道 c 的第 u 个参数位置上的更新量， $\text{Var}_{i \in S^t}(\cdot)$ 表示对当前轮参与客户端取方差。公式(3.17)首先计算每个参数位置在所有客户端间的方差，再对该通道内所有位置的方差取均值，得到代表整个通道离散程度的标量评分。

3.5.2 软掩码生成

得到各通道的方差评分 $\{v_c^{t,l}\}_{c=1}^{C_l}$ 后，服务器通过阈值判断构造软掩码。阈值的设定采用各通道方差的中位数作为基准，并乘以缩放系数 τ （默认 $\tau = 2.0$ ）：

$$T^{t,l} = \tau \cdot \text{Median} \left(\{v_c^{t,l}\}_{c=1}^{C_l} \right). \quad (3.18)$$

使用中位数而非均值的原因在于，均值对极端值敏感，若少数通道的方差极高，均值会随之偏大，导致大量通道的方差虽高于平均但仍被判断为正常；中位数则对极端值鲁棒，能够更稳定地反映“多数正常通道”的方差水平。

基于上述阈值，第 l 层第 c 个通道的软掩码值定义为：

$$m_c^{t,l} = \begin{cases} \alpha, & v_c^{t,l} > T^{t,l}, \\ 1, & v_c^{t,l} \leq T^{t,l}, \end{cases} \quad (3.19)$$

其中 $\alpha \in (0, 1)$ 为软掩码降权系数（默认 $\alpha = 0.3$ ）。方差超过阈值的通道被标记为“可疑通道”，其影响被缩放为原来的 α 倍；方差低于阈值的通道维持原有权重不变。

本文采用软掩码（即 $\alpha > 0$ ）而非将可疑通道直接清零（硬掩码），有其实际考量。首先，在 Non-IID 的 PFL 场景中，高方差通道并不一定意味着该通道完全被后门占据，其高方差有时也反映了诚实客户端对本地数据分布的正常差异化适配。软掩码通过部分保留这些通道的贡献，在降低恶意影响的同时减少对合理个性化信息的过度抑制。其次，当攻击者数量较少、恶意更新的绝对幅度相对有限时，软降权后的影响已足够小，不必完全清零。最后，将 $\{m_c^{t,l}\}_{c=1}^{C_l}$ 扩展为与层 l 权重张量同形的掩码矩阵 $\mathbf{M}^{t,l}$ ，同一输出通道内的所有参数共享相同的掩码值。

3.5.3 掩码引导修剪均值聚合

服务器将通道软掩码应用于每个客户端上传的 base 参数, 对可疑通道进行预先降权:

$$\tilde{\theta}_{B,i}^{t+1,l} = \mathbf{M}^{t,l} \odot \theta_{B,i}^{t+1,l}, \quad \forall i \in \mathcal{S}^t, \quad (3.20)$$

其中 $\odot$ 表示逐元素乘法。经软掩码处理后, 可疑通道中各参数的绝对值被整体缩小为 α 倍, 其在后续聚合中的影响相应减弱。

在此基础上, 对掩码处理后的参数执行修剪均值聚合。设本轮参与聚合的客户端总数为 $n = |\mathcal{S}^t|$, 修剪比例为 β (默认 $\beta = 0.2$), 令截断数量 $k = \lfloor \beta n \rfloor$ 。对第 l 层中每个参数位置 u , 将 n 个客户端的参数值 $\{\tilde{\theta}_{B,i}^{t+1,l}[u]\}_{i \in \mathcal{S}^t}$ 从小到大排序, 剔除最小的 k 个和最大的 k 个极端值, 对剩余的 $n - 2k$ 个值取均值:

$$\theta_B^{t+1,l}[u] = \frac{1}{n - 2k} \sum_{j=k+1}^{n-k} \text{sort}_j \left(\{\tilde{\theta}_{B,i}^{t+1,l}[u]\}_{i \in \mathcal{S}^t} \right), \quad (3.21)$$

其中 $\text{sort}_j(\cdot)$ 表示升序排列后第 j 小的元素。

软掩码降权与修剪均值聚合在作用维度上形成互补: 软掩码在通道维度上针对性地降低可疑结构位置的影响, 属于细粒度的空间选择性抑制; 修剪均值在客户端维度上剔除极端更新值, 属于粗粒度的全局稳健统计。前者能够在 Not-IID 下精准识别后门集中的通道, 后者能够处理恶意更新幅度远大于良性更新的情形, 两者配合使用比单独使用任一机制具有更稳健的防御效果。

3.5.4 服务器端聚合算法

算法3.3给出了服务器端通道方差评分、软掩码生成与修剪均值聚合的详细流程。

3.6 理论分析

3.6.1 客户端一致性约束的作用分析

为分析触发器破坏型增强与特征一致性约束联合作用的效果, 定义诚实客户端 i 在共享 base 参数 θ_B 下的表示一致性敏感度为:

$$\mathcal{R}_i(\theta_B) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}_i} \left\| B(\mathbf{x}^{(1)}; \theta_B) - B(\mathbf{x}^{(2)}; \theta_B) \right\|_2^2, \quad (3.22)$$

其中 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$ 为从 $\mathcal{A}_{tb}(\mathbf{x})$ 生成的两路高斯视图。 $\mathcal{R}_i(\theta_B)$ 在期望意义上等于 $\mathcal{L}_{cl}^{(i)}$ 的期望值, 最小化该量即要求 base 在两路扰动视图上输出稳定的特征表示。

算法 3.3 FedCLCM 服务器端聚合

Input: 上传参数 $\{\theta_{B,i}^{t+1}\}_{i \in S^t}$, 上轮全局参数 θ_B^t , 阈值系数 τ , 软掩码系数 α , 修剪比例 β

Output: 新全局参数 θ_B^{t+1}

```

1 foreach 卷积层  $l$  (仅 4 维权重张量) do
2   foreach 客户端  $i \in S^t$  do
3     计算更新量  $\Delta_i^{t,l} \leftarrow \theta_{B,i}^{t+1,l} - \theta_B^{t,l}$ ;
4   foreach 输出通道  $c = 1, \dots, C_l$  do
5     计算通道方差  $v_c^{t,l} \leftarrow \frac{1}{|Q_c^l|} \sum_{u \in Q_c^l} \text{Var}_{i \in S^t}(\Delta_{i,u}^{t,l})$ ;
6   计算阈值  $T^{t,l} \leftarrow \tau \cdot \text{Median}(\{v_c^{t,l}\}_{c=1}^{C_l})$ ;
7   foreach 输出通道  $c = 1, \dots, C_l$  do
8     if  $v_c^{t,l} > T^{t,l}$  then
9       置  $m_c^{t,l} \leftarrow \alpha$ ;
10    else
11      置  $m_c^{t,l} \leftarrow 1$ ;
12   将  $\{m_c^{t,l}\}$  扩展为掩码矩阵  $M^{t,l}$ , 同通道参数共享相同掩码值;
13   foreach 客户端  $i \in S^t$  do
14      $\tilde{\theta}_{B,i}^{t+1,l} \leftarrow M^{t,l} \odot \theta_{B,i}^{t+1,l}$ ;
15   令  $k \leftarrow \lfloor \beta |S^t| \rfloor$ ;
16   foreach 参数位置  $u$  do
17     对  $\{\tilde{\theta}_{B,i}^{t+1,l}[u]\}_{i \in S^t}$  升序排列, 取第  $k+1$  至  $n-k$  个元素的均值, 赋予  $\theta_B^{t+1,l}[u]$ ;
18 return  $\theta_B^{t+1}$ ;

```

考虑两类特征的行为差异。对于基于稳定语义结构的特征——例如图像中的轮廓、纹理等全局语义线索——在触发器破坏型增强去除了局部区域内容之后, 其特征激活受到的影响有限, 两路视图上的特征表示仍保持接近, 因此 $\mathcal{L}_{cl}^{(i)}$ 对应的项较小, 梯度不会强制 base 放弃这类特征。对于仅依赖于局部固定结构的触发模式——一旦该局部区域被擦除, 触发特征便无法稳定激活, 两路视图上的表示差异较大, 对应的 $\mathcal{L}_{cl}^{(i)}$ 项较大, 梯度会推动 base 降低对该类局部特征的敏感性。因此, 触发器破坏型增强与一致性约束的联合作用, 在功能上等价于一种对局部触发特征具有选择性的正则化, 使 base 倾向于依赖语义稳定特征而非局部不稳定特征。

3.6.2 服务器端掩码聚合的抑制效果

设第 l 层的理想聚合结果（即仅由诚实客户端更新确定的结果）为：

$$\bar{\theta}_B^{t+1,l} = \frac{1}{|\mathcal{H} \cap S^t|} \sum_{i \in \mathcal{H} \cap S^t} \theta_{B,i}^{t+1,l}. \quad (3.23)$$

设通道方差检测得到的可疑通道集合为 C_s^l , $\Pi_{C_s^l}(\cdot)$ 为仅保留可疑通道参数的投影算子。在软掩码作用后, 可疑通道上的实际聚合结果与理想聚合结果之间的偏差满足:

$$\left\| \Pi_{C_s^l}(\theta_B^{t+1,l} - \bar{\theta}_B^{t+1,l}) \right\|_2 \leq \alpha \cdot \sum_{i \in S^t} p_i \left\| \Pi_{C_s^l}(\theta_{B,i}^{t+1,l} - \bar{\theta}_B^{t+1,l}) \right\|_2, \quad (3.24)$$

即可疑通道上的异常偏差在聚合结果中整体缩小为无掩码时的 α 倍 ($\alpha = 0.3$), 有效降低了恶意通道对全局模型的支配程度。

相比于直接将可疑通道清零, 软掩码保留了 α 比例的通道信息, 使得因数据异构性而产生的正常高方差通道的贡献不被完全丢弃, 从而在防御强度与个性化性能代价之间取得更合理的平衡。

3.6.3 计算复杂度分析

在客户端侧, FedCLCM 相比标准 FedRep 引入的额外开销主要有两项: 触发器破坏型增强涉及元素级随机采样, 时间复杂度可忽略; 双视图生成需要对 base 额外执行一次前向传播, 复杂度约为 $O(F_{base})$, 其中 F_{base} 为 base 单次前向传播的浮点操作数。此外, 一致性损失的计算为向量内积, 复杂度为 $O(d)$ 。总体而言, 客户端侧的额外开销约等于一次 base 前向传播, 不涉及任何额外参数或模型结构, 实现简单且代价可控。

在服务器端, 通道方差估计需要对每个参数位置在所有客户端间计算方差, 若第 l 层参数量为 P_l 、参与客户端数为 n , 则该层的方差估计复杂度约为 $O(P_l \cdot n)$; 修剪均值聚合需要对每个参数位置执行排序, 复杂度约为 $O(P_l \cdot n \log n)$ 。上述操作不依赖辅助数据, 不涉及额外模型训练, 整体服务器端额外开销相对于标准聚合操作较为有限, 可以嵌入现有联邦训练框架中稳定运行。

3.7 本章小结

本章详细介绍了 FedCLCM 防御框架的完整设计。首先, 给出了系统模型、威胁模型与防御目标的形式化描述, 明确了本文方法针对的具体场景与评价准则。其次, 从总体层面阐述了 FedCLCM 客户端侧与服务器端协同防御的设计思路, 并以框架图展示了整体流程。随后, 从客户端和服务器端两个层面分别详细说明了防御机制的设计动机、实现方式、数学形式化描述与算法流程。最后, 对客户端一致性约束的作用机制、服务器端软掩码的抑制效果以及方法的计算复杂度进行了理论分析。

FedCLCM 的核心价值在于, 通过在客户端侧减少后门特征写入共享表示、在服

务器端降低异常通道对全局模型的扩散影响, 实现了覆盖后门传播完整链路的协同防御, 同时无需辅助数据与触发器先验, 计算和通信开销增量均在可控范围内。这些特点使得 FedCLCM 在实际 PFL 系统中具备较好的可落地性, 相关防御效果将在第四章的实验中得到系统验证。

第 4 章 实验设置与结果分析

4.1 引言

前一章已经从方法设计角度对鲁棒个性化联邦学习框架进行了形式化描述。为了验证所设计方法在个性化联邦学习场景下对后门攻击的抑制能力，本章进一步从实验角度对方法性能进行系统评估。结合 AdvPurge 原始论文与对应实验源码的设置，本章围绕实验环境与参数配置、整体防御性能、关键影响因素以及核心参数敏感性四个方面展开分析，并重点考察方法在保持主任务精度的同时降低后门攻击成功率的能力。

与传统联邦学习实验不同，个性化联邦学习场景中的实验评估不仅需要关注干净样本上的分类性能，还需要同时分析数据异构性、模型结构复杂度、触发器形式以及恶意客户端比例等因素对防御效果的影响。为此，本章在多个图像分类数据集和不同个性化程度设置下，对 AdvPurge 与多种联邦后门防御方法及个性化联邦学习基线方法进行比较，从而较为全面地展示该方法的有效性与适用范围。

4.2 实验设置

4.2.1 数据集与模型设置

为验证 AdvPurge 在不同任务复杂度下的防御性能，实验选取 MNIST、Fashion-MNIST 和 CIFAR-10 三个典型图像分类数据集。其中，MNIST 和 Fashion-MNIST 均包含 70000 张 28×28 灰度图像，类别数均为 10；CIFAR-10 包含 60000 张 32×32 彩色图像，同样包含 10 个类别。

在模型结构方面，参考个性化联邦学习及参数解耦场景下已有研究^[8,15]，在 MNIST、Fashion-MNIST 和 CIFAR-10 基础实验中采用由两层卷积层和两层全连接层构成的浅层卷积神经网络。考虑到深层网络更容易承载复杂特征表示，且在后门攻击场景下更能体现方法鲁棒性差异，实验进一步在 CIFAR-10 上引入 ResNet18 网络。为便于区分，后文将基于浅层卷积网络的 CIFAR-10 实验记为 CIFAR-10(C)，将基于 ResNet18 的 CIFAR-10 实验记为 CIFAR-10(R)。

4.2.2 数据划分与训练细节

实验采用 Dirichlet 分布对数据进行异构划分，以构造个性化联邦学习中的 Non-IID 场景。默认情况下，浓度参数设置为 $\alpha = 0.5$ ，共划分为 40 个客户端，其中 5 个客户端为恶意客户端。每轮通信中，服务器随机选择 25% 的客户端参与训练，即每轮共有 10 个客户端被采样参与联邦更新。全部实验统一训练 1000 轮。

在恶意客户端设置方面，默认将恶意客户端本地数据中的中毒样本比例设置为 20%。这一设置保证了后门攻击具有较强持续性，同时也使实验结果能够更加真实地反映连续攻击场景下的防御性能。与部分仅在少数轮次中进行后门注入的工作不同，本章实验采用持续注入策略，即恶意客户端在整个训练过程中持续执行带触发器样本训练，以检验方法在长期对抗条件下的稳定性。

4.2.3 攻击设置

实验中所有恶意客户端均使用相同的触发器模式和相同的目标标签，目标标签统一设置为 $y_t = 0$ 。为考察方法对不同后门注入形式的鲁棒性，实验选取以下三类典型触发器：

1. **BadNets**: 在图像右下角嵌入一个 3×3 的像素块触发器；
2. **Blend**: 以混合系数 $\alpha = 0.2$ 将水印图案与原始图像进行叠加；
3. **SIG**: 在像素空间中叠加幅值为 $A = 30$ 的正弦信号触发器。

上述三种触发器分别对应局部固定触发、全局混合触发和周期性信号触发，能够较为全面地覆盖图像后门攻击中常见的注入方式。因此，若某一防御方法能够在这三类触发器下保持较低的攻击成功率，则可在一定程度上说明其具备较好的触发器无关鲁棒性。

4.2.4 对比方法与评价指标

为了系统评估 AdvPurge 的防御能力，本章将其与三类基线方法进行比较：

1. 传统联邦平均方法 FedAvg^[1]；
2. 典型鲁棒聚合或防御方法，包括 Median^[12]、Trimmed Mean^[12]、Bulyan 以及 Multi-Krum^[11]；
3. 个性化联邦学习方法及相关防御方法，包括 FedRep^[6]、FedProto^[15] 以及 FedPD。

实验采用主任务准确率（ACC）与攻击成功率（ASR）作为评价指标。其中，ACC

用于衡量诚实客户端个性化模型在干净测试样本上的平均分类性能，定义为

$$\text{ACC} = \frac{1}{|\mathcal{D}_{clean}|} \sum_{(\mathbf{x}, y) \in \mathcal{D}_{clean}} \mathbb{I}(f(\mathbf{x}) = y), \quad (4.1)$$

其中， $\mathbb{I}(\cdot)$ 为示性函数。ASR 用于衡量带触发器样本被误分类至目标标签的比例，定义为

$$\text{ASR} = \frac{1}{|\mathcal{D}_{bd}|} \sum_{(\mathbf{x}, y_t) \in \mathcal{D}_{bd}} \mathbb{I}(f(\mathbf{x} \oplus \delta) = y_t), \quad (4.2)$$

其中， δ 表示攻击者注入的触发器， $\oplus$ 表示在输入样本上叠加触发器的操作。理想情况下，防御方法应在保持较高 ACC 的同时尽可能降低 ASR。

4.3 整体防御效果分析

4.3.1 与现有方法的总体比较

表4.1 给出了 AdvPurge 与多种基线方法在四组实验设置下的整体性能比较结果。可以看出，随着数据集复杂度和模型表达能力的提升，不同方法之间在安全性与可用性上的差异逐渐加大。

表 4.1 不同方法在各数据集上的整体性能比较

方法	MNIST		FMNIST		CIFAR-10(C)		CIFAR-10(R)	
	ACC	ASR	ACC	ASR	ACC	ASR	ACC	ASR
FedAvg	98.52	97.38	89.76	98.25	66.15	96.20	82.14	99.99
Median	98.90	0.14	89.35	6.19	58.23	6.75	21.55	75.29
Trimmed Mean	99.04	0.10	90.36	30.56	64.06	16.79	82.50	98.88
Bulyan	98.97	0.11	88.74	2.36	57.36	6.87	24.35	23.55
Multi-Krum	99.20	2.03	90.23	2.80	65.19	93.06	82.59	98.53
FedRep	98.77	0.30	92.10	2.21	74.55	9.09	88.25	56.33
FedProto	98.04	0.31	92.17	0.91	69.85	4.21	70.57	4.26
FedPD	98.32	0.23	91.49	1.04	69.17	3.85	69.64	4.69
AdvPurge	98.60	0.18	92.89	0.84	73.41	2.95	86.27	11.14

从 MNIST 的结果可以看出，除 FedAvg 外，大多数方法均能在简单任务上取得较高 ACC 和较低 ASR。这说明在低复杂度数据集上，后门防御的难度相对较小，传统鲁棒聚合策略也可以取得一定效果。然而，当数据复杂度上升至 FMNIST 时，传统联邦后门防御方法开始表现出明显局限性。例如，Trimmed Mean 在 FMNIST 上的

ASR 达到 30.56%，表明其在个性化联邦学习场景下难以有效区分由数据异构性带来的正常更新差异与恶意后门更新。相比之下，AdvPurge 在该数据集上取得了最高的 ACC（92.89%）和最低的 ASR（0.84%），体现出较好的安全性与可用性平衡。

在 CIFAR-10(C) 设置下，FedRep 取得了最高的 ACC（74.55%），但其 ASR 仍达到 9.09%。FedProto 和 FedPD 的 ASR 虽然较低，但主任务精度明显低于 FedRep 和 AdvPurge。这说明仅以攻击成功率作为单一评价标准并不足以全面反映防御效果，还需要同时考察模型在干净样本上的可用性。AdvPurge 在该设置下以 73.41% 的 ACC 和 2.95% 的 ASR 取得了较好的综合表现。

在 CIFAR-10(R) 深层网络设置下，各方法差异进一步扩大。FedAvg、Trimmed Mean 和 Multi-Krum 等传统方法虽然在部分情况下仍保持一定精度，但后门攻击成功率显著升高，难以满足安全需求；FedProto 和 FedPD 的 ASR 分别为 4.26% 和 4.69%，但其 ACC 仅为 70.57% 和 69.64%，明显低于 FedRep 与 AdvPurge。相比之下，AdvPurge 在 ACC 与 ASR 之间取得了更优综合平衡，表明其在深层网络和复杂数据集场景下仍具备较强的后门抑制能力。

4.4 影响因素分析

4.4.1 恶意客户端数量的影响

为进一步分析方法在不同攻击强度下的稳定性，表4.2 整理了不同恶意客户端数量下各方法在 CIFAR-10(R) 场景中的实验结果。其中，总客户端数保持不变，恶意客户端数量分别取 0、1、5、10 和 20。

表 4.2 不同恶意客户端数量下各方法在 CIFAR-10(R) 上的性能比较

方法	$n = 0$		$n = 1$		$n = 5$		$n = 10$		$n = 20$	
	ACC	ASR	ACC	ASR	ACC	ASR	ACC	ASR	ACC	ASR
FedAvg	83.75	2.37	83.66	94.38	82.14	99.99	82.32	100.00	82.07	100.00
FedPD	70.47	4.62	69.28	4.57	69.64	4.69	69.87	5.12	69.42	4.72
FedRep	88.23	1.70	87.62	9.94	88.25	56.33	87.77	53.42	87.92	78.85
AdvPurge	87.23	1.89	86.42	3.46	86.27	11.14	85.59	10.18	86.21	10.13

可以看出，当系统中不存在恶意客户端时，各方法的 ASR 均处于较低水平，此时 ASR 主要由模型的自然误分类所造成。随着恶意客户端数量增加，FedAvg 几乎立即失去防御能力；FedRep 在恶意客户端数量较少时仍能维持一定鲁棒性，但当恶意

客户端数量增加到 5 个及以上时，其 ASR 明显上升。相比之下，AdvPurge 在不同攻击强度下均能将 ASR 控制在较低水平，并保持相对稳定的 ACC，说明该方法对持续且多客户端协同的后门攻击具有较强抗性。

4.4.2 数据个性化程度的影响

在个性化联邦学习场景中，数据异构程度直接决定了本地模型差异和全局共享表示学习难度。表4.3 给出了不同 Dirichlet 浓度参数下各方法在 CIFAR-10(R) 场景中的性能。需要说明的是， α 越小，说明客户端间数据分布越异构，个性化程度越高；iid 表示客户端数据服从相同分布。

表 4.3 不同数据个性化程度下各方法在 CIFAR-10(R) 上的性能比较

方法	$\alpha = 0.2$		$\alpha = 0.5$		$\alpha = 0.8$		iid	
	ACC	ASR	ACC	ASR	ACC	ASR	ACC	ASR
FedAvg	86.19	97.34	82.14	99.99	82.58	94.36	84.33	100.00
FedProto	82.39	3.91	70.57	4.26	63.99	3.60	46.55	5.58
FedPD	82.01	4.14	69.64	4.69	62.38	4.25	46.68	4.91
FedRep	92.22	10.52	88.25	56.33	86.40	81.77	83.27	97.73
AdvPurge	90.36	12.84	86.27	11.14	84.17	13.70	82.32	15.09

由表4.3 可见，FedAvg 在所有数据分布设置下均无法有效抵御后门攻击；FedRep 在高异构场景下具有较高 ACC，但其 ASR 随着个性化程度下降而显著升高，说明其天然鲁棒性并不足以稳定应对持续后门注入。FedProto 和 FedPD 的 ASR 相对较低，但伴随着明显的精度下降。相比之下，AdvPurge 在不同 α 取值下均保持了较高的 ACC 和较稳定的低 ASR，说明该方法对不同程度的数据异构性具有较强适应能力。

4.4.3 触发器模式变化的影响

为了考察 AdvPurge 是否对特定触发器类型过度敏感，进一步在三类不同触发器下对其进行测试，结果如表4.4 所示。

从结果可以看出，AdvPurge 在三类触发器下均能保持较高的主任务准确率，说明其并不依赖于对某一特定触发器形态的先验建模。就 ASR 而言，Blend 触发器在 FMNIST 与 CIFAR-10 上表现出相对更强的攻击性，这与其全局混合式注入方式更难通过局部结构破坏完全抑制有关。尽管如此，AdvPurge 仍能将 ASR 控制在较低范围内，表明其具有较好的触发器泛化防御能力。

表 4.4 不同触发器模式下 AdvPurge 的性能比较

触发器类型	MNIST		FMNIST		CIFAR-10(C)		CIFAR-10(R)	
	ACC	ASR	ACC	ASR	ACC	ASR	ACC	ASR
BadNets	98.60	0.18	92.89	0.84	73.41	2.95	86.27	11.14
Blend	98.47	0.23	93.11	1.55	72.92	6.07	85.54	12.03
SIG	98.37	0.24	92.73	1.13	72.83	2.86	86.08	10.48

4.4.4 裁剪比例 β 的影响

在 AdvPurge 的服务器端聚合模块中, 裁剪比例 β 是影响防御强度的重要超参数。为分析其取值对模型性能的影响, 表4.5 给出了在 CIFAR-10(R) 场景下, 不同 β 取值对应的实验结果。

表 4.5 不同裁剪比例 β 下 AdvPurge 在 CIFAR-10(R) 上的性能比较

指标	0.0	0.1	0.2	0.3	0.4
ACC	87.62	87.03	86.57	86.27	85.25
ASR	33.83	26.58	16.12	11.14	10.87

由表4.5 可知, 当 $\beta = 0$ 时, 方法仍具有一定后门抑制能力, 这主要来源于客户端侧的对抗净化与 Base-Head 分离训练机制。然而, 随着 β 逐渐增大, 服务器在聚合阶段能够更充分地削弱异常参数带来的影响, 使 ASR 持续下降。与此同时, ACC 仅呈现小幅降低, 表明适度的通道或维度裁剪不会显著破坏模型的主任务性能。综合考虑防御收益与精度保持, 本组实验中 $\beta = 0.3$ 能够在 ACC 与 ASR 之间取得较优折中, 因此后续实验采用该设置。

4.5 本章小结

本章基于 AdvPurge 的原始实验结果, 对方法在个性化联邦学习后门防御场景下的性能进行了系统分析。首先, 给出了数据集、模型结构、训练细节、攻击设置、对比基线与评价指标等实验配置; 随后, 通过整体性能比较验证了 AdvPurge 在多个数据集和不同模型复杂度下的有效性, 说明该方法能够在保持较高主任务精度的同时显著降低后门攻击成功率; 进一步地, 通过恶意客户端数量、数据个性化程度、触发器类型以及裁剪比例等影响因素分析, 展示了方法在持续攻击、异构数据和多触发器条件下的鲁棒性。

总体来看, **AdvPurge** 在浅层模型和深层模型场景下均表现出较好的综合防御能力, 尤其在复杂数据分布和高攻击强度条件下仍能够维持相对稳定的主任务性能与较低的 **ASR**。上述实验结论为后续进一步替换和扩展为 **FedCLCM** 的实验结果分析提供了可复用的章节组织框架与写作基础。

参考文献

- [1] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. 2017: 1273-1282.
- [2] BAGDASARYAN E, VEIT A, HUA Y, et al. How to backdoor federated learning[C]//International Conference on Artificial Intelligence and Statistics. 2020: 2938-2948.
- [3] CHEN X, WANG X, CUI Q, et al. Overview of Backdoor Attacks and Defenses in Personalized Federated Learning[J]. Netinfo Security, 2025, 25(9): 1418-1438.
- [4] FALLAH A, MOKHTARI A, OZDAGLAR A. Personalized federated learning with theoretical guarantees: A model-agnostic meta-learning approach[J]. Advances in Neural Information Processing Systems, 2020, 33: 3557-3568.
- [5] LI T, HU S, BEIRAMI A, et al. Ditto: Fair and robust federated learning through personalization [J]. International Conference on Machine Learning, 2021: 6357-6368.
- [6] COLLINS L, HASSANI H, MOKHTARI A, et al. Exploiting shared representations for personalized federated learning[C]//International Conference on Machine Learning. 2021: 2089-2099.
- [7] LI X, JIANG M, ZHANG X, et al. Fedbn: Federated learning on non-iid features via local batch normalization[C]//International Conference on Learning Representations. 2021.
- [8] QIN Z, YAO L, CHEN D, et al. Revisiting personalized federated learning: Robustness against backdoor attacks[C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2023: 4743-4755.
- [9] LYU X, HAN Y, WANG W, et al. Lurking in the shadows: Unveiling stealthy backdoor attacks against personalized federated learning[C]//33rd USENIX Security Symposium (USENIX Security 24). 2024.
- [10] FAN M, HU Z, WANG F, et al. Bad-PFL: Exploring Backdoor Attacks against Personalized Federated Learning[C]//International Conference on Learning Representations. 2025.
- [11] BLANCHARD P, EL MHAMDI E M, GUERRAOU I R, et al. Machine learning with adversaries: Byzantine tolerant gradient descent[C]//Advances in Neural Information Processing Systems: vol. 30. 2017.
- [12] YIN D, CHEN Y, RAMCHANDRAN K, et al. Byzantine-robust distributed learning: Towards optimal statistical rates[C]//International Conference on Machine Learning. 2018: 5650-5659.
- [13] FUNG C, YOON C J, BESCHASTNIKH I. Mitigating sybils in federated learning poisoning[C]//arXiv preprint arXiv:1808.04866. 2018.
- [14] XIE C, HUANG K, CHEN P Y, et al. Dba: Distributed backdoor attacks against federated learning [C]//International Conference on Learning Representations. 2019.

-
- [15] TAN Y, LONG G, LIU L, et al. Fedproto: Federated prototype learning across heterogeneous clients [C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 36: 8. 2022: 8432-8440.
 - [16] GU T, DOLAN-GAVITT B, GARG S. Badnets: Identifying vulnerabilities in the machine learning model supply chain[C]//Proceedings of the IEEE Access. 2019.
 - [17] CHEN X, LIU C, LI B, et al. Targeted backdoor attacks on deep learning systems using data poisoning[J]. arXiv preprint arXiv:1712.05526, 2017.
 - [18] BARNIM, KALLAS K, TONDI B. A new backdoor attack in CNNs by training set corruption without label poisoning[C]//2019 IEEE International Conference on Image Processing (ICIP). 2019: 101-105.
 - [19] NGUYEN T A, TRAN A. WaNet – Imperceptible Warping-based Backdoor Attack[C]//International Conference on Learning Representations. 2021.
 - [20] ZHANG J, ZHU C, SUN X, et al. FLPurifier: Backdoor defense in federated learning via decoupled contrastive training[J]. IEEE Transactions on Information Forensics and Security, 2024.
 - [21] MADRY A, MAKELOV A, SCHMIDT L, et al. Towards Deep Learning Models Resistant to Adversarial Attacks[C]//International Conference on Learning Representations. 2018.

致 谢

感谢那位最先制作出博士学位论文 L^AT_EX 模板的物理系同学！

感谢 William Wang 同学对模板移植做出的贡献！

感谢 @weijianwen 学长开创性的工作！

感谢 @sjtug 对 0.10 及之后版本的开发和维护工作！

感谢所有为模板贡献过代码的同学们，以及所有测试和使用模板的各位同学！

感谢 L^AT_EX 和 SJTUThesis，帮我节省了不少时间。

学术论文和科研成果目录

学术论文

- [1] Chen H, Chan C T. Acoustic cloaking in three dimensions using acoustic metamaterials[J]. Applied Physics Letters, 2007, 91:183518.
- [2] Chen H, Wu B I, Zhang B, et al. Electromagnetic Wave Interactions with a Metamaterial Cloak[J]. Physical Review Letters, 2007, 99(6):63903.

专利

- [1] 第一发明人, “永动机”, 专利申请号 202510149890.0.

个人简历

基本情况

某某，yyyy 年 mm 月生于 xxxx。

教育背景

- yyyy 年 mm 月至今，上海交通大学，博士研究生，xx 专业
- yyyy 年 mm 月至 yyyy 年 mm 月，上海交通大学，硕士研究生，xx 专业
- yyyy 年 mm 月至 yyyy 年 mm 月，上海交通大学，本科，xx 专业

研究兴趣

L^AT_EX 排版

联系方式

- 地址：上海市闵行区东川路 800 号，200240
- E-mail: john_smith@sjtu.edu.cn